

## Variabile aleatoare

Variabila aleatoare sau intamplatoare este legata de experimente aleatoare, care desfasurate in timp conduc la procese aleatoare. In cadrul teoriei statistice a semnalelor, procesul (semnalul) aleator este un model mai realist decat semnalul determinist pentru o serie intreaga de semnale atat utile (date, imagini, sunete) cat si perturbatoare (zgomote) din sistemele de prelucrare si transmitere a informatiei. Teoria statistica a semnalelor este strans legata de teoria probabilitatilor si de teoria multimilor, care impreuna permit introducerea notiunii de spatiu probabilistic.

### 1. Spatiu probabilistic

Baza pentru definirea variabilei aleatoare este spatiul probabilistic  $= (H, \mathcal{A}, P)$ , numit de unii autori si model statistic. Acesta este compus din trei elemente: multimea esantioanelor  $H$ , campul evenimentelor  $\mathcal{A}$ , si masura probabilistica  $P$ .

- multimea esantioanelor  $H$ : multimea tuturor rezultatelor posibile  $\eta$  ale unui experiment aleator.

*Exemplu:* numerele corespunzatoare apelurilor sosite la o anumita centrala de comutatie, fetele aparute la aruncarea zarului, durata de viata a unei anumite componente a unui sistem, tensiunea retelei masurat la bornele unei prize.

- campul evenimentelor  $\mathcal{A}$ : multimea nevida, continand submultimi ale multimii  $H$ , avand urmatoarele proprietati:

a)  $H \in \mathcal{A}$ ,

b) Din  $A \in \mathcal{A}$  rezulta  $\bar{A} \in \mathcal{A}$ ,

c) Din  $A_1, A_2, \dots \in \mathcal{A}$ , rezulta  $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$ .

In aceasta definitie se noteaza cu  $\bar{A}$  complementul multimii  $A$ , adica toate elementele multimii  $H$  care nu sunt in  $A$ . In consecinta, un rezultat  $\eta_i \in H$  poate fi element al mai multor evenimente.

*Exemplu:* la aruncarea zarului, multimea rezultatelor este  $H = \{\eta_1, \eta_2, \dots, \eta_6\}$  unde  $\eta_i$  = aparitia fetei  $i$  si un camp posibil de evenimente este  $\mathcal{A} = \{\emptyset, \{\eta_1\}, \{\eta_1, \eta_2\}, \{\eta_2, \eta_3, \eta_4, \eta_5, \eta_6\}, \dots, H\}$

- Măsura probabilistică  $P$ : o măsura specială care se poate asocia elementelor câmpului evenimentelor, o funcție care se poate defini pe acest câmp  $\mathcal{A}$ . Domeniul valorilor ei este intervalul  $\{0, 1\}$  al numerelor reale; se poate spune că funcția  $P$  este o aplicație a câmpului  $\mathcal{A}$  pe intervalul  $\{0, 1\}$ . Proprietățile lui  $P$  sunt definite prin trei axiome (Kolmogorov):
  - a)  $P(A) \geq 0$
  - b)  $P(H) = 1$
  - c)  $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$  unde  $A_i$  sunt disjuncte două câte două.

Definițiile probabilității:

- ca frecvență relativă:  $P(A) = \lim_{n \rightarrow \infty} \frac{n_A}{n}$  unde un experiment aleator este repetat de  $n$  ori și evenimentul  $A$  apare de  $n_A$  ori
- în sens clasic:  $P(A) = \frac{N_A}{N}$  unde  $N$  este numărul total de rezultate ale experimentului (numărul elementelor din  $H$  finit), din care evenimentul  $A$  intervine de  $N_A$  ori.

Legi uzuale ale probabilității:

- $P(\emptyset) = 0$  unde  $\emptyset$  este evenimentul nul,
- $P(A) \leq 1$ ,
- Dacă  $A \cup \bar{A} = H$  și  $A \cap \bar{A} = \emptyset$  atunci  $P(\bar{A}) = 1 - P(A)$
- Dacă  $A \subset B$  atunci  $P(A) \leq P(B)$
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- $P(A \cup B) \leq P(A) + P(B)$
- Dacă  $A_i \cap A_j = \emptyset \quad \forall i \neq j$  și  $A_1 \cup A_2 \cup \dots \cup A_n = H$  atunci
 
$$P(A) = P(A \cap H) = P(A \cap A_1) + P(A \cap A_2) + \dots + P(A \cap A_n)$$

adică seturile  $A_i$  sunt mutual exclusive și complete.

Probabilitatea conditionata:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \text{sau} \quad P(B|A) = \frac{P(A \cap B)}{P(A)}$$

$$\text{sau in forma Bayes:} \quad P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

In contextul de mai sus,  $P(A)$  se numeste probabilitatea *a priori* iar  $P(A|B)$  se numeste probabilitatea *a posteriori* a evenimentului  $A$ .  
Din axiomele de mai sus rezulta:

$$P(A|B) \geq 0$$

$$P(H|B) = 1$$

$$P(A_1 \cup A_2 | B) = P(A_1 | B) + P(A_2 | B) \quad \text{daca } A_1 \text{ si } A_2 \text{ sunt disjuncte}$$

Se spune ca doua evenimente sunt statistic independente daca:

$$P(A \cap B) = P(A)P(B) \quad \text{si atunci mai rezulta:}$$

$$P(A|B) = P(A)$$

$$P(B|A) = P(B)$$

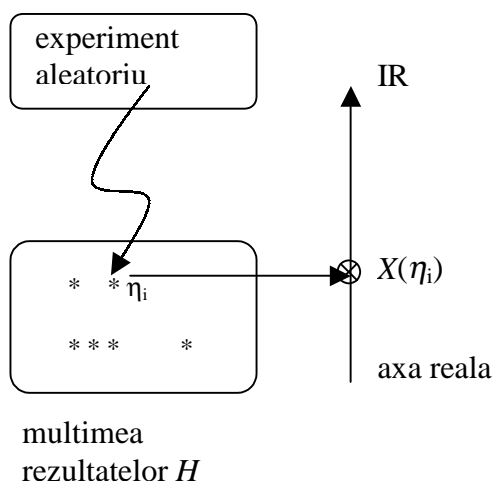
$$P(A|H) = P(A) \quad \text{deoarece} \quad P(H) = 1$$

## 2. Definitia variabilei aleatoare reale $X(\eta)$

Variabila aleatoare reala  $X(\eta)$  este reprezentarea multimii rezultatelor  $H$  a unui experiment aleator pe multimea  $\mathbb{R}$  a numerelor reale cu urmatoarele proprietati:

$$\text{a) } \{X(\eta) \leq x\} \in \mathcal{A} \quad \text{pentru fiecare } x \in \mathbb{R}$$

$$\text{b) } P(\{X(\eta) = -\infty\}) = P(\{X(\eta) = +\infty\}) = 0$$



Valoarea unei variabile aleatoare  $X(\eta)$  pentru un argument  $\eta = \eta_i$  se numeste o *realizare* a variabilei (vezi fig. alaturata). Variabila aleatoare poate fi continua sau discreta. Daca multimea rezultatelor  $H$  este numarabila, atunci  $X(\eta)$  este o variabila aleatoare discreta

(aruncarea cu zarul), dacă mulțimea rezultatelor  $H$  este nenumarabilă, atunci variabila aleatoare este continuă (măsurarea valorilor unei tensiuni).

*Exemplu:* aruncarea zarului;  $H = \{\text{toate fetele posibile}\}$

$\eta$	1	2	3	4	5	6
$X(\eta)$	0	0	5	10	10	100

### 3. Funcția de repartiție a probabilității și densitatea de probabilitate

Permit *caracterizarea completă* a unei variabile aleatoare.

Funcția de repartiție a probabilității este:

- $F_x(x) = P(\{X(\eta) \leq x\})$ .

Proprietățile ei sunt:

- a)  $F_x(-\infty) = 0$
- b)  $F_x(+\infty) = 1$
- c)  $F_x(x)$  crește monoton

- Densitatea de probabilitate este:

$$f_x(x) = \frac{dF_x(x)}{dx}$$


Această derivată există numai pentru variabile cu funcție de repartiție absolut continuă. În punctele în care funcția de repartiție are salturi, se introduc distribuții  $\delta$  ponderate cu un factor egal cu mărimea saltului lui  $F_x(x)$  în punctul respectiv.

Funcția de repartiție se poate deduce din densitate prin integrare:


$$F_x(x) = \int_{-\infty}^x f_x(u) du.$$

*Exemple:*

Variabile aleatoare discrete  
(Aruncarea cu banul )



Variabile aleatoare continue  
(Masurarea timpului de viata)



Daca o variabila aleatoare discreta ia valorile  $x_i$  cu  $i = 1, \dots, M$  atunci densitatea de probabilitate este de forma:

$$f_x(x) = \sum_{i=1}^M a_i \delta(x - x_i) \quad \text{unde } a_i \text{ este saltul lui } F_x(x) \text{ la } x_i :$$

$$a_i = P(\{X(\eta) = x_i\})$$

Introducand cele doua relatii in expresia lui  $F_x(x)$  se obtine :

$$F_x(x) = \int_{-\infty}^x f_x(u) du = \sum_{x_i \leq x} P(\{X(\eta) = x_i\})$$

Proprietati ale densitatii de probabilitate a unei variabile aleatoare :

$$a) \quad f_x(x) \geq 0 \text{ pentru toti } x$$

$$b) \quad \int_{-\infty}^{+\infty} f_x(x) dx = 1$$

Se poate calcula din  $f_x(x)$  probabilitatea ca  $X(\eta)$  sa ia o valoare intre  $x_1$  si  $x_2$  :

$$P(\{x_1 \leq X(\eta) \leq x_2\}) = \int_{x_1}^{x_2} f_x(x) dx$$

Pentru variabile discrete datorita proprietatii de filtrare a lui  $\delta$ , probabilitatea devine :

$$P(\{x_1 \leq X(\eta) \leq x_2\}) = \sum_{x_i \leq x_2} P(\{X(\eta) = x_i\})$$

**4.Valori medii ale variabilelor aleatoare** (valori asteptate = expected values)

Permit caracterizarea incompleta, partiala a variabilelor aleatoare.

• Momente de ordin  $n$

$$\overline{X}^{(n)} = E\{[X(\eta)]^n\} = \int_{-\infty}^{+\infty} x^n f_x(x) dx = m_x^{(n)}$$

Pentru  $n = 1$  (valoare medie liniara):

$$\overline{X} = \int_{-\infty}^{+\infty} x f_x(x) dx \quad \text{pentru variabile continue}$$

$$\overline{X} = \sum_{k=1}^n P_k x_k \quad \text{pentru variabile discrete}$$

$$P_k = P(\{X(\eta) = x_k\})$$

Operatorul de mediere se poate extinde si asupra functiilor de variabila aleatoare. Daca  $g(X(\eta))$  este o functie bijectiva de variabila aleatoare  $X(\eta)$ , atunci:

$$E\{g(X(\eta))\} = \int_{-\infty}^{\infty} g(x) dF_x(x)$$

Daca desitatea de probabilitate  $f_x(x)$  exista, atunci:

$$E\{g(X(\eta))\} = \int_{-\infty}^{\infty} g(x) f_x(x) dx$$

Operatorul de mediere este un operator liniar:

$$E\{ag(X(\eta))\} = aE\{g(X(\eta))\}$$

$$E\{g(X(\eta)) + h(Y(\eta))\} = E\{g(X(\eta))\} + E\{h(Y(\eta))\}$$

Pentru  $n = 2$  (valoare medie patratica):

$$\overline{X}^{(2)} = \int_{-\infty}^{+\infty} x^2 f_x(x) dx \quad \text{pentru variabile continue}$$

$$\overline{X}^{(2)} = \sum_{k=1}^n P_k x_k^2 \quad \text{pentru variabile discrete}$$

• Momente centrale de ordin  $n$ :

$$\begin{aligned} \overline{(X - \overline{X})^{(n)}} &= E\{[X(\eta) - \overline{X}]^n\} = \int_{-\infty}^{+\infty} (x - \overline{X})^n f_x(x) dx \\ &= \mu_x^{(n)} \end{aligned}$$

Pentru  $n = 2$  (varianta):

$$\overline{(X - \overline{X})^{(2)}} = \int_{-\infty}^{+\infty} (x - \overline{X})^2 f_x(x) dx \quad \text{pentru variabile continue}$$

$\text{Var}\{X(\eta)\} = \sigma_x^2$ ;  $\sigma_x$  este dispersia (deviatia standard) a v.a.

Se poate arata ca:

$$\text{Var}\{X(\eta)\} = \sigma_x^2 = \overline{X^{(2)}} - \{\overline{X}\}^2$$

Statistica clasica este o statistica de ordin 2, care descrie variabilele aleatoare numai cu valori medii de ordinul 1 si 2.

Statisticile de ordin superior folosesc pentru caracterizarea v.a. si valorile medii de ordin  $n > 2$ . Valorile medii de ordin superior lui 2 se numesc cumulanti. Interesul crescand din ultimul timp pentru statisticile de ordin superior este justificat de urmatoarea teorema:

**O v.a. poate fi complet caracterizata daca se cunosc valorile medii pana la ordinul  $n$ , cand  $n \rightarrow \infty$ .**

## 5. Ansamble de doua variabile aleatoare

Pe acelasi spatiu al esantioanelor  $H$  se pot defini mai multe variabile aleatoare, de exemplu  $X(\eta)$  si  $Y(\eta)$ , proiectand multimea  $H$  a rezultatelor posibile pe doua multimi  $IR$  de numere reale.

Pentru aceste doua variabile se pot defini:

## 6. Functia de repartitie a ansamblului:

$$F_{XY}(x,y) = P(\{X(\eta) \leq x\} \cap \{Y(\eta) \leq y\}) \text{ si}$$

## Densitatea de probabilitate a ansamblului:

$$f_{xy}(x,y) = \frac{\delta^2 F_{xy}(x,y)}{\delta x \delta y}.$$

Evenimentele sigure in aceasta situatie sunt  $\{X(\eta) \leq \infty\}$ , respectiv  $\{Y(\eta) \leq \infty\}$ , iar evenimentele imposibile  $\{X(\eta) \leq -\infty\}$ , respectiv  $\{Y(\eta) \leq -\infty\}$ .



Rezulta astfel pentru ansamblul de doua v.a. urmatoarele

**Proprietati ale functiei de repartitie de ansamblu,  $F_{XY}(x,y)$ :**

$$F_{XY}(x, +\infty) = F_X(x)$$

$$F_{XY}(+\infty, y) = F_Y(y)$$

$$F_{XY}(x, -\infty) = 0$$

$$F_{XY}(-\infty, y) = 0$$

$$F_{XY}(+\infty, +\infty) = 1$$

Functia de repartitie a ansamblului se poate determina prin integrarea densitatii de probabilitate a ansamblului:

$$F_{XY}(x, y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{XY}(u, v) du dv.$$

Densitatile marginale de probabilitate se pot determina cu relatiile:

$$f_X(x) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dx$$

**Proprietatile densitatii de probabilitate de ansamblu:**

- este o functie nenegativa:

$$f_{XY}(x, y) \geq 0$$

- satisface conditia de completitudine:

$$\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{XY}(x, y) dx dy = 1$$

Observatie: Pentru v.a. discrete densitatile de probabilitate se inlocuiesc cu probabilitati, iar integrarile prin sumari.

**Independenta statistica a doua variabile aleatoare**

Este una din relatiile interesante pentru studiul sistemelor de prelucrare a informatiei, deoarece efectele variabilelor pot fi luate in considerare separat. Conditia de independenta statistica este:

$$f_{XY}(x, y) = f_X(x) \cdot f_Y(y).$$

Rezulta pentru functiile de repartitie relatia:

$$F_{XY}(x, y) = F_X(x) \cdot F_Y(y).$$

### Valori medii (momente) ale ansamblului

- Moment de ordin k, m

$$m_{xy}^{(k,m)} = E\{X^k(\eta)Y^m(\eta)\} = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x^k y^m f_{XY}(x, y) dx dy$$

pentru  $k = 1, m = 1$ , se obtine functia de corelatie mutuala

$$m_{xy}^{(1,1)} = Cor\{XY\} = E\{XY\}$$

- Moment centrat de ordin k, m

$$\begin{aligned} \mu_{xy}^{(k,m)} &= E\{(X(\eta) - m_X^{(1)})^k (Y(\eta) - m_Y^{(1)})^m\} = \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x - m_X^{(1)})^k (y - m_Y^{(1)})^m f_{XY}(x, y) dx dy \end{aligned}$$

pentru  $k = 1, m = 1$ , se obtine functia de covariatie mutuala

$$\begin{aligned} \mu_{xy}^{(1,1)} &= Cov\{XY\} = E\{(X(\eta) - m_X^{(1)}) (Y(\eta) - m_Y^{(1)})\} = \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x - m_X^{(1)}) (y - m_Y^{(1)}) f_{XY}(x, y) dx dy \end{aligned}$$

Intre Cor si Cov exista relatia :

$$Cov\{XY\} = Cor\{XY\} - E\{X\} \cdot E\{Y\} = E\{XY\} - E\{X\} \cdot E\{Y\}$$

Variabile necorelate :

$$Cov\{XY\} = 0 \rightarrow E\{XY\} = E\{X\} \cdot E\{Y\}$$

Variabile ortogonale :

$$Cor\{XY\} = E\{XY\} = 0$$

Doua variabile aleatoare independente statistic sunt necorelate :

$$E\{X(\eta)Y(\eta)\} = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyf_{XY}(x, y)dxdy = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyf_X(x)f_Y(y)dxdy =$$

$$\int_{-\infty}^{+\infty} xf_X(x)dx \int_{-\infty}^{+\infty} yf_Y(y)dy = E\{X(\eta)\}E\{Y(\eta)\}$$

Reciproca nu este intotdeauna adevarata: conditia de independenta statistica este mai „tare” decat cea de necorelare (decorelare).

Coeficient de corelatie

$$\rho_{XY} = \frac{\mu_{XY}^{(1,1)}}{\sigma_X \sigma_Y} = \frac{E\{(X(\eta) - m_X^{(1)})(Y(\eta) - m_Y^{(1)})\}}{|\sqrt{E\{(X(\eta) - m_X^{(1)})^2\} \cdot E\{(Y(\eta) - m_Y^{(1)})^2\}}|}$$

limitele domeniului de variatie ale coeficientului sunt :

$$-1 \leq \rho_{XY} \leq 1$$

*Demonstratie:*

$$E\left\{\left(\frac{X(\eta) - m_X^{(1)}}{\sigma_X} \pm \frac{Y(\eta) - m_Y^{(1)}}{\sigma_Y}\right)^2\right\} \geq 0$$

valoarea medie a partii din stanga a relatiei este :

$$1 \pm 2\rho_{XY} + 1 \geq 0$$

care este valabila pentru ambele semne numai pentru  $|\rho_{XY}| \leq 1$

Coeficientul de corelatie arata relatia dintre doua variabile aleatoare :

1. Sunt decorelate pentru :

$$\rho_{XY} = 0$$

2. Daca sunt liniar dependente :  $Y(\eta) = aX(\eta)$ , atunci se poate arata ca  $\rho_{XY} = 1$  pentru  $a > 0$  si  $\rho_{XY} = -1$  pentru  $a < 0$ .

## Funcția de repartiție condiționată și densitatea de probabilitate condiționată.

$$F_X(x/B) = P(\{X(\eta) \leq x\} / B)$$

$$f_X(x/B) = \frac{dF_X(x/B)}{dx}$$

$$\text{Pentru } B = \{X(\eta) \leq a\}$$

$$F_X(x/B) = \frac{P(\{X(\eta) \leq x\} \cap \{X(\eta) \leq a\})}{P(\{X(\eta) \leq a\})}$$

$$x \geq a \rightarrow P(\{X(\eta) \leq x\} \cap \{X(\eta) \leq a\}) = P(\{X(\eta) \leq a\})$$

$$\Rightarrow F_X(x/B) = 1$$

$$x \leq a \rightarrow P(\{X(\eta) \leq x\} \cap \{X(\eta) \leq a\}) = P(\{X(\eta) \leq x\})$$

$$\Rightarrow F_X(x/B) = \frac{F_X(x)}{F_X(a)}$$

$$f_X(x/B) = \frac{dF_X(x/B)}{dx} = \begin{cases} \frac{f_X(x)}{F_X(a)} = \frac{f_X(x)}{\int_{-\infty}^a f_X(u) du} & \text{pentru } x \leq a \\ 0 & \text{pentru } x \geq a \end{cases}$$

$$\text{Pentru } B = \{Y(\eta) \leq y\}$$

$$F_X(x/B) = \frac{F_{XY}(x, y)}{F_Y(y)}$$

$$f_X(x/B) = \frac{f_{XY}(x, y)}{f_Y(y)}$$

## 7. Densitati de probabilitate uzuale

### Distributii discrete

- Uniforma, cand rezultatele experimentului aleator sunt egal probabile:  $P(X = x_i) = 1/n \quad i = 1, 2, 3, \dots, n$
- Binomiala, cand intereseaza probabilitatea de aparitie a unui eveniment  $A$  de probabilitate  $p$  de  $k$  ori in sirul de  $n$  repetitii ale experimentului:

$$P(X = k) = C_n^k p^k (1-p)^{n-k}, \quad k = 1, 2, \dots, n \quad \text{unde :}$$

$$C_n^k = \frac{n!}{k!(n-k)!} \quad \text{si } m! = m(m-1)(m-2)\dots(3)(2)(1); \quad 0! = 1$$

*Exemplu:* Probabilitatea de eronare a  $k$  simboluri intr-un cuvnt de lungime  $n$

- Poisson, cand intereseaza numarul  $k$  al rezultatelor pozitive ale unui experiment intr-un interval de timp de lungime  $T$  :

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots$$

cu  $\lambda = \lambda' T$  unde  $\lambda'$  este numarul rezultatelor pozitive care apar in unitatea de timp.

*Exemplu:* Numarul apelurilor primite de o centrala telefonica sau numarul electronilor emisi de un catod fierbinte.

### Distributii continue:

- Distributia uniforma

$$f_x(x) = \begin{cases} 1/(b-a), & a \leq x \leq b \\ 0 & \text{in rest} \end{cases}$$

Media si varianta varibilei aleatoare uniforme sunt:


$$m_x = \frac{b+a}{2}$$

$$\sigma_x^2 = \frac{(b-a)^2}{12}$$

*Exemplu:* Eroarea de cuantizare

- Distributia normala (gaussiana) unidimensionala

Este cea mai utilizata, avand o forma analitica simpla; are multiple aplicatii ca urmare a teoremei limita centrala.



Pentru schimbarea de variabila :

$z = (x - m_x)/\sigma_x$ , integrala precedenta devine:

$$P(X > a) = \int_{(a-m_x)/\sigma_x}^x \frac{1}{\sqrt{2\pi}} \exp(-z^2/2) dz$$

O metoda de calcul a acestei integrale se bazeaza pe integrala tabulata  $Q(y)$ :


$$Q(y) = \frac{1}{\sqrt{2\pi}} \int_y^x \exp(-z^2/2) dz, \quad y > 0$$

$$P(X > a) = Q[(a - m_x)/\sigma_x]$$

Deasemenea se poate calcula:

$$P(X \leq a) = 1 - Q(y) \text{ sau:}$$

$$P(X \leq 0) = 1/2$$




- Distributia normala bidimensionala

$$f_{xy}(x, y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \exp \left\{ \frac{-1}{2(1-\rho^2)} \left[ \left( \frac{x-m_X}{\sigma_X} \right)^2 + \left( \frac{y-m_Y}{\sigma_Y} \right)^2 - \frac{2\rho(x-m_X)(y-m_Y)}{\sigma_X\sigma_Y} \right] \right\}$$

## 8. Transformari de variabile aleatoare

*Cazul unidimensional:*



*Exemplu:* caracteristica unui amplificator

In ce consta problema: daca este cunoscuta  $f_X(x)$  trebuie determinata  $f_Y(y)$


a) Cazul cand  $g(x)$  este bijectiva:

$g: \mathbb{R} \rightarrow \mathbb{R}$

$$P\{x \leq X \leq x + dx\} = P\{y \leq Y \leq y + dy\}$$

$\Downarrow$

$$f_X(x)dx = f_Y(y)dy \Rightarrow f_Y(y) = f_X(x) \left| \frac{dy}{dx} \right|_{x=g^{-1}(y)}$$




b) Cazul cand  $g$  este bijectiva pe portiuni:

$g: \mathbb{R} \rightarrow \mathbb{R}$


$$\forall y \in \mathbb{R}, \exists x_i \in \mathbb{R} \Rightarrow g(x_i) = y$$

$\Downarrow$

$$f_Y(y) = \sum \frac{f_X(x_k)}{\left| \frac{dy}{dx} \right|_{x_k=g^{-1}(y)}}$$



***Cazul bidimensional:***



$$X \xrightarrow{g_1 g_2} Y : \begin{cases} y_1 = g_1(x_1, x_2) \\ y_2 = g_2(x_1, x_2) \end{cases}$$

$$Y \xrightarrow{\varphi_1 \varphi_2} X : \begin{cases} x_1 = \varphi_1(y_1, y_2) \\ x_2 = \varphi_2(y_1, y_2) \end{cases}$$

$$P\{x \in \Delta x\} = P\{y \in \Delta y\}$$


$$f_{x_1 x_2}(x_1 x_2) \cdot \Delta x = f_{y_1 y_2}(y_1 y_2) \cdot \Delta y \Rightarrow f_{y_1 y_2}(y_1 y_2) = f_{x_1 x_2}(x_1 x_2) \cdot \frac{\Delta y}{\Delta x}$$

$$\frac{\Delta y}{\Delta x} \rightarrow \text{Jacobianul transformării}$$

$$\lim_{\Delta x \rightarrow 0} \frac{\Delta y}{\Delta x} = \frac{\Delta(y_1 y_2)}{\Delta(x_1 x_2)} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_2}{\partial x_1} \\ \frac{\partial y_1}{\partial x_2} & \frac{\partial y_2}{\partial x_2} \end{bmatrix} \Rightarrow f_{y_1 y_2}(y_1 y_2) = f_{x_1 x_2}(x_1 x_2) \cdot \frac{1}{\Delta}$$

*Exemplu:* schimbarea de coordonate rectangulare / polare





$$\begin{aligned} x_1 &= \rho \cos(\theta) = y_1 \cos(y_2) & \rho &= y_1 = \sqrt{x_1^2 + x_2^2} \\ x_2 &= \rho \sin(\theta) = y_1 \sin(y_2) & \theta &= y_2 = \arctg \frac{x_2}{x_1} \end{aligned}$$

$$\Delta_{y \rightarrow x} = \begin{vmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_2}{\partial x_1} \\ \frac{\partial y_1}{\partial x_2} & \frac{\partial y_2}{\partial x_2} \end{vmatrix} = \begin{vmatrix} \cos(y_2) & \sin(y_2) \\ -y_1 \sin(y_2) & y_1 \cos(y_2) \end{vmatrix} = y_1 = \sqrt{x_1^2 + x_2^2}$$

$$f_{x_1 x_2}(x_1 x_2) = f_{y_1 y_2}(y_1 y_2) \cdot \frac{\Delta x}{\Delta y} = \frac{1}{\rho} \cdot f_{y_1 y_2}(y_1 y_2)$$

$$f_{y_1 y_2}(y_1 y_2) = \rho \cdot f_{x_1 x_2}(x_1 x_2)$$

Modificarea coordonatelor duce la schimbarea distributiilor

$$F_{x_1 x_2}(x_1 x_2) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f_{x_1 x_2}(u, v) du dv$$

$$F_{y_1 y_2}(y_1 y_2) = \int_{-\infty}^{y_1} \int_{-\infty}^{y_2} f_{y_1 y_2}(u, v) du dv$$

## 9. Variabile aleatoare complexe

Variabila aleatoare complexa  $Z$  se defineste cu ajutorul variabilelor aleatoare reale  $X$  si  $Y$ :

$$Z = X + jY$$

Valoarea medie of  $g(Z)$  este definita ca:

$$E\{g(Z)\} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(z) f_{X,Y}(x, y) dx dy$$

media lui  $Z$ ,  $m_Z$ , este :

$$m_Z = E\{Z\} = E\{X\} + jE\{Y\} = m_X + jm_Y$$

varianța este :

$$\sigma_Z^2 = E\{|Z - m_Z|^2\}$$

covarianța lui  $Z_m, Z_n$  este :

$$C_{Z_m Z_n} = E\{(Z_m - m_{Z_m})^* (Z_n - m_{Z_n})\}$$

unde  $*$  semnifică complex conjugat

## 10. Vector aleator

Variabila aleatoare scalară ia valori pe axa reală, iar vectorul aleator ia valori într-un spațiu  $m$  dimensional  $R_m$ . Funcția de repartiție a vectorului aleator și densitatea sa de probabilitate se pot defini ca pentru ansambluri de  $m$  variabile aleatoare:

$$F_{X_1, \dots, X_m}(x_1, \dots, x_m) = P[(X_1 \leq x_1) \dots (X_m \leq x_m)]$$

$$f_{X_1, X_2, \dots, X_m}(x_1, x_2, \dots, x_m) = \frac{\partial^m F_{X_1, \dots, X_m}(x_1, \dots, x_m)}{\partial x_1 \partial x_2 \dots \partial x_m}$$

Parametrii importanți sunt valorile medii și covarianțele:

$$m_{X_i} = E\{X_i\}$$

$$\sigma_{X_i X_j} = E\{X_i X_j\} - m_{X_i} m_{X_j}$$

Legile probabilistice pentru vectori aleatori pot fi formulate concis, folosind notații vectoriale. Ansamblul de  $m$  variabile aleatoare  $X_1, \dots, X_m$  poate fi reprezentat ca un vector coloană cu  $m$  componente:

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_m \end{bmatrix} \text{ sau } \mathbf{X}^T = [X_1 X_2, \dots, X_m]$$

Vectorul medie și matricea de covarianță sunt:

$$\mathbf{m}_X = E(\mathbf{X}) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \dots \\ E(X_m) \end{bmatrix}$$

$$\Sigma_X = E\{\mathbf{X}\mathbf{X}^T\} - \mathbf{m}_X \mathbf{m}_X^T = \begin{bmatrix} \sigma_{X_1 X_1} & \sigma_{X_1 X_2} & \dots & \sigma_{X_1 X_m} \\ \sigma_{X_2 X_1} & \sigma_{X_2 X_2} & \dots & \sigma_{X_2 X_m} \\ \dots & \dots & \dots & \dots \\ \sigma_{X_m X_1} & \sigma_{X_m X_2} & \sigma_{X_m X_1} & \sigma_{X_m X_m} \end{bmatrix}$$

componentele sunt necorelate daca:

$$\sigma_{X_i} \sigma_{X_j} = \sigma_{ij} = 0, \quad \forall i \neq j$$

si independente daca:

$$f_{X_1, X_2, \dots, X_m}(x_1, x_2, \dots, x_m) = \prod_{i=1}^m f_{X_i}(x_i)$$

## 11. Functia caracteristica

- Definitie

Este transformata Fourier a densitatii de probabilitate.

$$\Phi_X(j\omega) = \begin{cases} \mathbf{R} \rightarrow \mathbf{C} \\ \Phi_X(j\omega) = E\{e^{j\omega X}\} \end{cases}$$

pentru variabile discrete :

$$\Phi_X(j\omega) = \sum_{k=1}^{\infty} e^{j\omega x_k} P_X(X = x_k)$$

pentru variabile continue :

$$\Phi_X(j\omega) = \int e^{j\omega x} f_X(x) dx$$

- Proprietati:

$$\Phi_X(j\omega) = \mathcal{F}^* \{f_X(x)\}$$

$$f_X(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \Phi_X(j\omega) e^{-j\omega x} d\omega$$

- Legatura cu momentul unei variabile aleatoare

Daca se diferentiaza functia caracteristica:

$$\frac{d\Phi_X(j\omega)}{d\omega} = j \int_{-\infty}^{\infty} x e^{j\omega x} f_X(x) dx$$

$$\left. \frac{d\Phi_X(j\omega)}{d\omega} \right|_{\omega=0} = j \int_{-\infty}^{\infty} x f_X(x) dx = jE\{X\}$$

$$E\{X^n\} = (-j)^n \left. \frac{d^n \Phi_X(j\omega)}{d\omega^n} \right|_{\omega=0}$$

$$\Phi_X(j\omega) = \sum_{n=0}^{\infty} \left. \frac{d^n \Phi_X(j\omega)}{d\omega^n} \right|_{\omega=0} \frac{\omega^n}{n!}$$

$$\Phi_X(j\omega) = \sum_{n=0}^{\infty} E\{X^n\} \frac{(j\omega)^n}{n!} = \sum_{n=0}^{\infty} m_n \frac{(j\omega)^n}{n!}$$

## Semnale si procese aleatoare


Ținând cont de măsura în care ele sunt previzibile în timp, semnalele pot fi ierarhizate în felul următor:

- Semnale deterministe, a căror evoluție în timp se poate prevedea, ele fiind descrise de o funcție de timp cunoscută, ca de exemplu  $X(t) = A \cos(\omega t + \varphi)$ .
- Semnale condiționat – deterministe, a căror evoluție în timp se poate prevedea parțial, deoarece un parametru al semnalului este o variabilă aleatoare, ca de exemplu:
 
$$\begin{cases} X(t) = A(\eta) \cos(\omega t + \varphi) \text{ sau} \\ X(t) = A \cos(\omega(\eta)t + \varphi) \text{ sau} \\ X(t) = A \cos(\omega t + \varphi(\eta)) \end{cases}$$
- Semnale aleatoare, a căror evoluție în timp este practic imprevizibilă și care vor fi studiate în continuare.

### 1. Definiția semnalului aleator

Un semnal aleator real este o funcție de doi parametri  $X(\eta, t)$  unde  $\eta$  ia valori în spațiul eșantioanelor, iar  $t$ , de obicei, ia valori pe axa reală, pozitivă și are semnificația de timp.

Orice semnal aleator se obține ca urmare a efectuării unui experiment care constă în alegerea din spațiul eșantioanelor  $H$  a unui eșantion elementar  $\eta_i$  care determină alegerea funcției  $X(\eta_i, t)$  din familia de funcții  $X(\eta, t)$  (vezi figura).



Fiecărei valori  $\eta$  îi corespunde o funcție  $X(\eta, t)$ , notată  $X_\eta(t)$ , numită *realizare particulară* sau funcție eșantion a semnalului.



Dacă este cunoscut procesul aleator prin mulțimea realizărilor sale particulare, în orice moment de timp  $t$  se obține o variabilă aleatoare  $X_t(\eta)$ . În consecință, după cum variază cei doi parametri  $\eta$  și  $t$ , deosebim următoarele cazuri:

- $\eta$  și  $t$  variabile:  $X(\eta, t)$  este un semnal aleator, adică o familie de realizări particulare;
- $\eta$  variabil și  $t$  fix:  $X(\eta, t) = X_t(\eta)$  este o variabilă aleatoare;
- $\eta$  fix și  $t$  variabil:  $X(\eta, t) = X_\eta(t)$  este o realizare particulară, adică o funcție de timp obișnuită;
- $\eta$  și  $t$  fixe,  $X(\eta, t)$  reprezintă un număr.

## 2. Clasificarea semnalelor aleatoare.

- Semnale aleatoare în timp continuu, sau simplu semnale aleatoare, constituite din o familie nenumărabila de variabile aleatoare  $X_t(\eta)$  cu  $t \in \mathfrak{R}$ .
  1. Dacă  $X_t(\eta)$  pentru un  $t$  oarecare este o variabilă aleatoare continuă, semnalul este de amplitudine continuă (figura a1); un exemplu îl poate constitui tensiunea de la bornele unei prize electrice.
  2. Dacă  $X_t(\eta)$  pentru un  $t$  oarecare este o variabilă aleatoare discretă, semnalul este de amplitudine discretă (figura a2); un exemplu îl poate constitui un semnal de date într-o transmisie asincronă, când șirul de date poate începe la orice moment de timp.
- Semnale aleatoare în timp discret sau serii aleatoare care reprezintă o mulțime numărabilă de funcții aleatoare notate  $X_n(\eta)$ , unde  $t = nT$  cu  $n \in \mathbb{Z}$ .
  1. Dacă pentru un  $n$  oarecare,  $X_n(\eta)$  este o variabilă aleatoare continuă, seria este de amplitudine continuă (figura b1); un exemplu îl poate constitui un semnal de amplitudine continuă (analogic) eșantionat.
  2. Dacă pentru un  $n$  oarecare,  $X_n(\eta)$  este o variabilă aleatoare discretă, seria este de amplitudine discretă (figura b2) și se mai numește și lanț aleator; un

exemplu îl poate constitui un semnal analogic  
eșantionat și cuantizat



### 3. Funcții de repartiție și densități de probabilitate ale semnalelor aleatoare în timp continuu

- Funcția de repartiție a probabilităților de ordinul 1 se definește ca pentru o variabilă aleatoare continuă obținută din semnalul aleator la un moment oarecare de timp:

$$F_X(x, t) = P(X(\eta, t) \leq x)$$

- Densitatea de probabilitate de ordinul 1 se definește tot ca pentru o variabilă aleatoare continuă și este:

$$f_X(x, t) = \frac{\partial F_X(x, t)}{\partial x}$$

- Funcția de repartiție de ordinul  $n$  se referă la  $n$  v.a. continue, considerate la  $n$  momente de timp diferite:

$$F_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n; t_1, t_2, \dots, t_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n)$$

unde am notat  $X_i = X(\eta, t_i)$ .

- Densitatea de probabilitate de ordin  $n$  este:

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n; t_1, \dots, t_n) = \frac{\partial^n F_{X_1, \dots, X_n}(x_1, \dots, x_n; t_1, \dots, t_n)}{\partial x_1 \dots \partial x_n}$$

Funcțiile de repartiție și densitățile de probabilitate ale semnalului aleator depind de momentele de timp  $t_i$  la care sunt considerate variabilele aleatoare.

- Funcția de repartiție a ansamblului de doua semnale aleatoare continue in timp  $X(\eta, t)$  și  $Y(\eta, t)$  definite pe același spațiu al eșantioanelor este:

$$F_{XY}(x, y; t_1, t_2) = P(X(\eta, t_1) \leq x, Y(\eta, t_2) \leq y)$$

- Densitatea de probabilitate a ansamblului de doua semnale aleatoare continue in timp mai sus considerat este:

$$f_{XY}(x, y; t_1, t_2) = \frac{\partial^2 F_{XY}(x, y; t_1, t_2)}{\partial x \partial y}$$

Dacă două semnale sunt definite pe același spațiu al eșantioanelor, atunci se poate verifica dacă sunt statistic independente.

#### 4. Semnale aleatoare statistic independente

Definiție: Două semnale aleatoare  $X(\eta, t)$  și  $Y(\eta, t)$  definite pe același spațiu al eșantioanelor se numesc statistic independente dacă pentru orice momente  $t_{11}, \dots, t_{1i}$  din intervalul de timp pe care este definit  $X(\eta, t)$  și pentru orice momente  $t_{21}, \dots, t_{2j}$  din intervalul de timp pe care este definit  $Y(\eta, t)$ , variabilele aleatoare  $X(\eta, t_{11}), \dots, X(\eta, t_{1i})$  sunt statistic independente de variabilele aleatoare  $Y(\eta, t_{21}), \dots, Y(\eta, t_{2j})$ . Atunci, cu  $t_1 \in T_x, t_2 \in T_y$  ( $T_x$  și  $T_y$  sunt intervalele pe care se observă semnalele aleatoare  $X, Y$ ):

$$F_{XY}(x, y; t_1, t_2) = F_X(x, t_1) \cdot F_Y(y, t_2)$$

$$f_{XY}(x, y; t_1, t_2) = f_X(x, t_1) \cdot f_Y(y, t_2)$$

În interpretare fizică, între două semnale statistic independente nu se poate stabili nici o legătură; ele provin de regulă din surse diferite și de aceea efectele lor în sistemele de prelucrare a informației pot fi luate în considerație separat.

Pentru cazul în care variabilele aleatoare  $X(\eta, t_{1i})$  și  $Y(\eta, t_{2j})$  sunt discrete, condiția de independență statistică devine:

$$P_{kn} = P_k P_n \quad \text{unde: } P_{kn} = P(X(\eta, t_{1i}) = a_k, Y(\eta, t_{2j}) = b_n),$$



$$P_k = P(X(\eta, t_{1i}) = a_k)$$

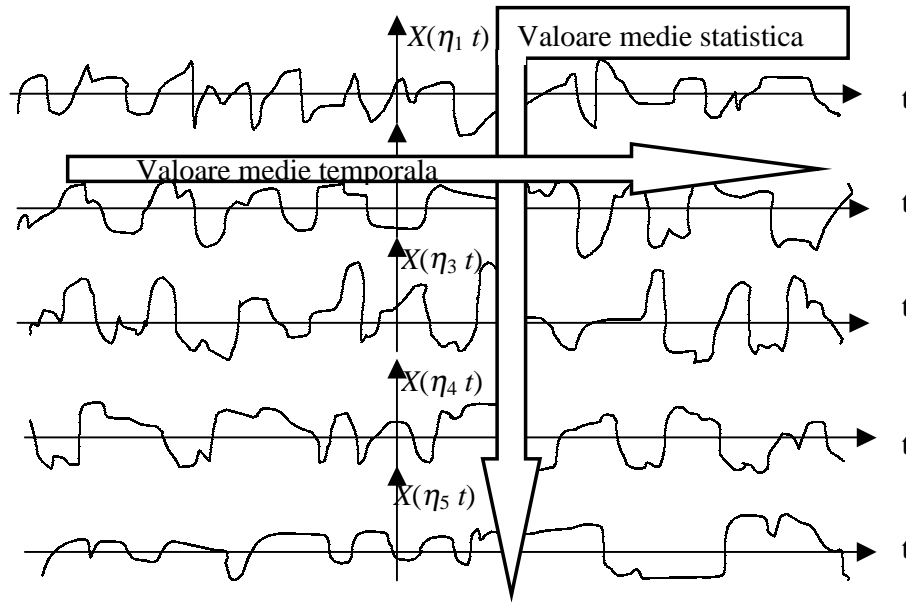
$$P_n = P(Y(\eta, t_{2j}) = b_n)$$

iar  $a_k$  si  $b_n$  sunt valori ale variabilelor  $X$  si  $Y$ , alese din șirurile de valori posibile ale acestor variabile:

$\{a_1, a_2, \dots, a_k, \dots\}$  respectiv  $\{b_1, b_2, \dots, b_n, \dots\}$

### 5. Valori medii statistice ale semnalelor aleatoare

Pentru un semnal aleator, pe mulțimea realizărilor sale particulare, se pot defini doua tipuri de valori medii: valori medii statistice ale realizărilor particulare la un anumit moment de timp



si valorile medii temporale ale fiecărei realizări particulare.

Valorile medii statistice sunt de fapt valori medii ale variabilelor aleatoare considerate la un anumit moment de timp si care devin astfel funcții de timp. Aceste valori medii se definesc ca si pentru variabile aleatoare, ceea ce se vede in continuare:

- Valoarea medie liniara

$$m_x^{(1)}(t) = E\{X(\eta, t)\} = \int_{-\infty}^{+\infty} x f_X(x, t) dx$$

- Valoarea medie pătratica

$$m_x^{(2)}(t) = E\{X^2(\eta, t)\} = \int_{-\infty}^{+\infty} x^2 f_X(x, t) dx$$

- Varianta

$$\sigma_X^2(t) = E\{(X(\eta, t) - m_X(t))^2\} = \int_{-\infty}^{+\infty} (x - m_X(t))^2 f_X(x, t) dx$$

- Funcția de autocorelație, care măsoară legătura care există între valorile semnalului aleator la momente de timp diferite

$$R_{X_1 X_2}(t_1, t_2) = E\{X(\eta, t_1)X(\eta, t_2)\} = \int_{-\infty}^{\infty} \int_{-\infty}^{+\infty} x_1 x_2 f_{X_1 X_2}(x_1 x_2; t_1, t_2) dx_1 dx_2$$

- Funcția de autovariație, care este funcția de autocorelație a semnalului centrat pe valoarea sa medie și are expresia:

$$C_{X_1 X_2}(t_1, t_2) = E\{(X(\eta, t_1) - m_x(t_1))(X(\eta, t_2) - m_x(t_2))\} = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x_1 - m_x(t_1))(x_2 - m_x(t_2)) f_{X_1 X_2}(x_1 x_2; t_1, t_2) dx_1 dx_2$$

Se poate arăta că se păstrează relația dedusă la variabile aleatoare :

$$C_{X_1 X_2}(t_1, t_2) = R_{X_1 X_2}(t_1, t_2) - m_x(t_1)m_x(t_2)$$

- Funcția de intercorelație sau de corelație mutuală între două semnale aleatoare  $X(\eta, t_1)$  și  $Y(\eta, t_2)$

$$R_{XY}(t_1, t_2) = E\{X(\eta, t_1)Y(\eta, t_2)\} = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xy f_{XY}(xy; t_1, t_2) dx dy$$

- Funcția de covariație sau de intervariație

$$C_{XY}(t_1, t_2) = E\{(X(\eta, t_1) - m_x(t_1))(Y(\eta, t_2) - m_y(t_2))\} = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x - m_x(t_1))(y - m_y(t_2)) f_{XY}(x, y; t_1, t_2) dx dy$$

- Semnale aleatoare necorelate : două semnale aleatoare definite pe același spațiu al esanțioanelor sunt necorelate dacă pentru toate valorile  $t_1 \in T_x$  și  $t_2 \in T_y$  variabilele aleatoare respective sunt necorelate, adică dacă :

$$E\{X(\eta, t_1)Y(\eta, t_2)\} = E\{X(\eta, t_1)\}E\{Y(\eta, t_2)\}$$

- Semnale ortogonale : două semnale aleatoare definite pe același spațiu al esanțioanelor sunt ortogonale dacă pentru toate valorile  $t_1 \in T_x$  și  $t_2 \in T_y$  variabilele aleatoare respective sunt ortogonale, adică dacă :

$$E\{X(\eta, t_1)Y(\eta, t_2)\} = 0$$

- Dacă două semnale aleatoare sunt necorelate și dacă cel puțin unul din ele are valoarea medie nulă, atunci ele sunt și ortogonale
- Dacă două semnale sunt statistic independente, atunci ele sunt și necorelate. Reciproca nu este întotdeauna adevărată!

## 6. Valori medii statistice ale semnalelor aleatoare discrete

Valorile medii statistice se calculeaza pe ansamblul realizarii particulare considerate la momente arbitrate de timp  $t_1, t_2, \dots, t_i, \dots$ , deci asupra variabilei aleatoare ce rezulta in aceste momente de timp. Se mai numesc valori medii pe ansamble si depind de alegerea momentelor de timp alese.

Acestea sunt:

- Valoare medie (moment de ordinul 1, media liniara)

$$m_x(n) = E[X(\eta, n)] = \sum_k a_k P_k(n)$$

unde  $\{a_1, \dots, a_k, \dots, a_N\}$  reprezinta ansamblul valorilor posibile.

- Valoarea patratica medie (moment de ordinul 2)

$$m_x^{(2)}(n) = E[X^2(\eta, n)] = \sum_k a_k^2 P_k(n)$$

- Varianta

$$\sigma^2(n) = E[X^2] - (E[X])^2$$

- Momentul de ordinul n

$$m_x^{(n)}(n) = E[X^n(\eta, n)] = \sum_k a_k^n P_k(n)$$

- Functia de autocorelatie

$$R_{xx}(n_1, n_2) = E[X(\eta, n_1)X(\eta, n_2)] = \sum_{i=1}^N \sum_{j=1}^N a_i a_j P_{ij}(n_1, n_2)$$

$$P_{ij}(n_1, n_2) = P(X(\eta, n_1) = a_i, X(\eta, n_2) = a_j)$$

- Functia de corelatie mutuala a doua semnale aleatoare  $X(\eta, t)$  si  $Y(\eta, t)$

$$R_{xy}(n_1, n_2) = \sum_{i=1}^N \sum_{j=1}^N a_i b_j P_{ij}(a_i, b_j; n_1, n_2)$$

cu

$$P_{ij}(a_i, b_j; n_1, n_2) = P(X(\eta, n_1) = a_i, Y(\eta, n_2) = b_j)$$

unde  $a_i, i=[1,N]$ , sunt valorile posibile ale lui  $X(\eta, n_1)$  iar  $b_j, j=[0,N]$ , sunt valorile posibile ale lui  $Y(\eta, n_2)$ .

- Functia de autovariatie

$$C_{xx}(n_1, n_2) = R_{xx}(n_1, n_2) - m_x(n_1)m_x(n_2)$$

- Functia de covariatie a doua semnale  $X(\eta, t)$  si  $Y(\eta, t)$

$$C_{xy}(n_1, n_2) = R_{xy}(n_1, n_2) - m_x(n_1)m_y(n_2)$$

## 7. Valori medii pentru semnale aleatoare complexe

$$Z(\eta, t) = X(\eta, t) + jY(\eta, t)$$

deducem  $E[Z(\eta, t)] = E[X(\eta, t)] + jE[Y(\eta, t)]$

- Momentul de ordinul 2

$$M_z(t_1, t_2) = E[Z(\eta, t_1)Z(\eta, t_2)]$$

- Functia de autocorelatie continua

$$R_{zz}(t_1, t_2) = E[Z(\eta, t_1)Z^*(\eta, t_2)]$$

- Functia de autocorelatie discreta

$$R_{zz}(n_1, n_2) = E[Z(\eta, n_1)Z^*(\eta, n_2)]$$

cu proprietatile:

$$M_z(t_1, t_2) = M_z(t_2, t_1), \quad \forall t_1, t_2$$

simetrie hermitica  $R_{zz}(t_1, t_2) = R_{zz}^*(t_2, t_1), \quad \forall t_1, t_2$

- Corelatia statistica de ordinul n

$$R_x(t_1, t_2, \dots, t_n) = E[X(\eta, t_1)X(\eta, t_2) \dots X(\eta, t_n)]$$

### 8. Medii temporale pentru semnale in timp continuu

Mediile temporale se calculeaza pe o realizare particulara

$X(\eta, t)$  si depind de parametrul  $\eta$  din spatiul esantioanelor.

Acestea sunt:

- Valoarea medie liniara

$$m_{x\eta} = \overline{X_{\eta}(t)} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} X(\eta, t) dt = \overline{X_{\eta}(t_0 + t)}$$

Deci nu depinde de originea timpului  $t_0$ .

Valoarea medie temporală reprezintă componenta continuă a semnalului și este ea însăși o variabilă aleatoare deoarece depinde de  $\eta$ . Valoarea sa medie statistică este:

$$E[\overline{X_{\eta}(t)}] = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} E[X(\eta, t)] dt = m_x$$

Rezultă că valoarea medie statistică a tuturor valorilor medii liniare temporale este egală cu valoarea medie liniară statistică a semnalului.

- Valoarea patratică medie (moment de ordinul 2)

$$\overline{[X_{\eta}(t)]^2} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} [X(\eta, t)]^2 dt = \overline{[X_{\eta}(t_0 + t)]^2}$$

Valoarea patratică medie, nu depinde de originea timpului și reprezintă puterea medie a semnalului pe sarcină unitară.

- Momentul de ordinul n

$$\overline{[X_{\eta}(t)]^n} = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} [X(\eta, t)]^n dt = \overline{[X_{\eta}(t_0 + t)]^n}$$

- Functia de autocorelatie

Depinde de diferenta dintre momentele de timp considerate.

$$\begin{aligned} R_{xx,\eta}(t_1, t_2) &= \overline{X_{\eta}(t_1 + t)X_{\eta}(t_2 + t)} = \\ &= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} X(\eta, t_1 + t)X(\eta, t_2 + t) dt = R_{xx,\eta}(t_2 - t_1) \end{aligned}$$

- Functia de corelatie mutuala

$$\begin{aligned} R_{xy,\eta}(t_1, t_2) &= \overline{X_{\eta}(t_1 + t)Y_{\eta}(t_2 + t)} = \\ &= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} X(\eta, t_1 + t)Y(\eta, t_2 + t) dt = R_{xy,\eta}(t_2 - t_1) \end{aligned}$$

Se poate demonstra ca:  $R_{xy,\eta}(\tau) \neq R_{xy,\eta}(-\tau)$

$$R_{xy,\eta}(\tau) = R_{yx,\eta}(-\tau); \quad \tau = t_2 - t_1$$

- Functia de autovariatie

$$C_{xx,\eta}(t_1, t_2) = \overline{[X_{\eta}(t_1 + t) - m_x][X_{\eta}(t_2 + t) - m_x]} = C_{xx,\eta}(t_2 - t_1)$$

- Functia de covariatie

$$C_{xy,\eta}(t_1, t_2) = \overline{[X_{\eta}(t_1 + t) - m_x][Y_{\eta}(t_2 + t) - m_y]} = C_{xy,\eta}(t_2 - t_1)$$

## 9. Medii temporale pentru semnale in timp discret

Daca semnalul aleator este definit doar in momente discrete de timp, in formulele anterioare se inlocuieste indicele  $t \in \mathfrak{R}$  prin indicele  $n \in Z$ , stiind ca  $t_n = nT$  unde  $T$  reprezinta intervalul de timp intre doua momente de timp, iar integrarea se inlocuieste printr-o insumare. De exemplu:

- Valoarea medie liniara

$$m_{x\eta} = \lim_{N \rightarrow \infty} \frac{1}{N+1} \sum_{i=-\frac{N}{2}}^{\frac{N}{2}} X(\eta_0, i)$$

S-a notat  $X(\eta_0, i)$  pentru  $X(\eta_0, iT)$  sau, inca,  $X(\eta_0, t_i)$ . Indicele  $\eta$  este un element arbitrar al spatiului esantioanelor.

- Momentul de ordinul n

$$m_{x\eta}^{(n)} = \lim_{N \rightarrow \infty} \frac{1}{N+1} \sum_{i=-N/2}^{N/2} X^n(\eta_0, i)$$

- Functia de autocorelatie

$$R_{xx, \eta_0}(m) = \lim_{N \rightarrow \infty} \frac{1}{N+1} \sum_{i=-\frac{N}{2}}^{\frac{N}{2}} X(\eta_0, i) X(\eta_0, i+m)$$

Functia de corelatie mutuala

- $$R_{xy, \eta_0}(m) = \lim_{N \rightarrow \infty} \frac{1}{N+1} \sum_{i=-\frac{N}{2}}^{\frac{N}{2}} X(\eta_0, i) Y(\eta_0, i+m)$$

- Functia de corelatie circulara

$$r_{xy}(m) \cong \frac{1}{N+1} \sum_{i=-\frac{N}{2}}^{\frac{N}{2}} X(\eta_0, i) Y(\eta_0, i+m)$$

Observatii:

- ♦ In cazul seriilor aleatoare digitale (semnale digitale sau semnale discrete in timp cu amplitudine discreta), variabila aleatoare  $X(\eta_0, i)$  (respectiv  $Y(\eta_0, i)$ ) ia valori in alfabetul finit  $\{a_1, a_2, \dots, a_k, \dots, a_n\}$  (si, respectiv,  $\{b_1, b_2, \dots, b_j, \dots, b_m\}$ ).

Autocorelatia ca medie temporala devine:

$$R_{xx, \eta_0}(h) = \lim_{N \rightarrow \infty} \frac{1}{N+1} \sum_{k=-\frac{N}{2}}^{\frac{N}{2}} a_k a_{k+h}$$

Corelatia mutuala temporala a doua semnale digitale este:

$$R_{xy, \eta_0}(h) = \lim_{N \rightarrow \infty} \frac{1}{N+1} \sum_{k=-\frac{N}{2}}^{\frac{N}{2}} a_k b_{k+h}$$

- ♦ Corelatiile temporale de ordinul n depind de realizarea particulara aleasa prin parametrul  $\eta$  si de n variabile  $\tau_1, \tau_2, \dots, \tau_{n-1}$  reprezentand diferentele dintre momentele de timp considerate :

$$\tau_i = t_{i+1} - t_i, \quad i = 1, \dots, n$$

## 10. Stationaritate

Definitie: Un semnal aleator este *stationar* daca proprietatile sale statistice sunt invariante in raport cu



schimbarea originii timpului sau, echivalent, la orice translatie de timp.

Doua semnale sunt simultan stationare daca fiecare este stationar si daca proprietatile lor statistice simultane sunt invariante la orice translatie de timp.

Stationaritatea poate fi in *sens strict* sau in *sens larg*.

### **Stationaritate in sens strict**

Definitie(stationaritate in sens strict sau tare): Un semnal este stationar tare sau in sens strict daca functia sa de repartitie (legea temporală) de orice ordin este invarianta la orice translatie de timp  $\tau$ .

$$F_n(x_1, \dots, x_n; t_1, \dots, t_n) = F_n(x_1, \dots, x_n; t_1 + \tau, \dots, t_n + \tau)$$

Rezulta ca densitatile de probabilitate de orice ordin  $n$  sunt invariante la orice translatie de timp.

Daca semnalul este o secventa digitala aleatoare  $X(\eta, n)$  cu valori in alfabetul  $\{a_1, a_2, \dots, a_k, \dots, a_N\}$ , atunci stationaritatea in sens strict presupune:

- $P_i = P(X_n = a_i)$  este independenta de  $n$
- $P(a_1, \dots, a_N) = P(X_1 = a_1, \dots, X_n = a_N)$  depinde numai de diferentele de timp.

### **Stationaritate in sens larg**

Definitie(stationaritate in sens larg sau slaba): Un semnal este stationar in sens larg sau slab daca functiile sale de repartitie de ordinul 1 si 2 sunt invariante la orice translatie de timp  $\tau$ .

$$F_1(x, t) = F_1(x, t + \tau) = F_1(x)$$

$$F_2(x_1, x_2; t_1, t_2) = F_2(x_1, x_2; t_1 + t, t_2 + t) = F_2(x_1, x_2; \tau), \quad \tau = t_2 - t_1$$

Ca urmare densitatile de probabilitate de ordinul 1 si 2 sunt invariante la orice translatie de timp si deci:

$$m_x = E[X(\eta, t)] - \text{nu depinde de timp}$$

$m_x^{(2)} = E[X^2(\eta, t)]$  - nu depinde de timp

$R_{xx}(\tau) = E[X(\eta, t)X(\eta, t + \tau)]$  - depinde de diferenta de timp

$R_{xy}(\tau) = E[X(\eta, t)Y(\eta, t + \tau)]$  - depinde de diferenta de timp

In cazul unui semnal digital, stationaritatea in sens larg se defineste prin:

- $P_i = P(X_n = a_i)$  este independenta de  $n$
- $P_{ij}(n, k) = P(X_n = a_i, X_k = a_j) = P_{ij}(n - k)$  depinde numai de  $n - k$ .

Stationaritatea in sens larg se mai numeste stationaritate pana la ordinul al doilea. Spre deosebire de aceasta, stationaritatea simpla de ordinul al doilea se refera doar la invarianta in timp a proprietatilor statistice de ordinul al doilea, ceea ce nu implica si stationaritatea de ordinul intai. De exemplu, in cazul unei secvente digitale aleatoare, probabilitatea

$$P_i = P(X_n = a_i) = \sum_{j=1}^N P(X_n = a_i, X_k = a_j) = \sum_{j=1}^N P_{ij}(n - k)$$

nu depinde de alegerea lui  $X_k$  dar poate depinde de  $n$  desi  $P_{ij}(n - k)$  depinde numai de  $(n - k)$ .

In concluzie: stationaritatea in sens larg este verificata prin relatiile:

- cazul semnalelor discrete in timp
  - $E[X_n]$  independenta de  $n$
  - $E[|X_n|^2] < \infty$
  - $R_{xx}(n_1, n_2) = R_{xx}(n_2 - n_1)$
- cazul semnalelor continue in timp

- $E[ X(\eta, t )]$  independenta de t
- $E[| X(\eta, t )|^2 ] < \infty$
- $R_{xx}( t_1, t_2 ) = R_{xx}( t_2 - t_1 )$
- continuitatea in origine a functiei de autocorelatie care asigura continuitatea realizarii particulare in medie patratica.

## 11. Ergodicitate

Stationaritatea este o proprietate a unui semnal aleator care nu poate fi determinată decât din mulțimea tuturor realizărilor particulare. Din punct de vedere practic, interesant este cazul în care o singură realizare particulară poate fi luată drept model pentru întregul proces aleator.

Un asemenea caz îl reprezintă semnalele aleatoare staționare ale căror medii statistice sunt egale cu mediile temporale corespunzătoare efectuate pe o singură realizare particulară, de care se dispune simplu. Aceste semnale se numesc ergodice.

Definiție (ergodicitate tare): Un semnal staționar se numește *ergodic tare* sau în *sens strict* dacă mediile temporale până la ordinul  $n$  ale unei realizări particulare arbitrare sunt egale, cu probabilitate 1, cu mediile statistice de același ordin, pentru orice  $n$ .

Definiție (ergodicitate slabă): Un semnal staționar se numește *ergodic slab* sau în *sens larg* dacă mediile statistice de ordinul întâi și al doilea sunt egale, cu probabilitatea 1, cu mediile temporale ale unei realizări particulare arbitrare de același ordin.

Egalitatea, cu probabilitatea 1, a unei medii statistice cu o medie temporală, de exemplu, în cazul ordinului întâi, înseamnă convergența în probabilitate:

$$m_X(t) = E[X(\eta, t)]$$

$$m_{X\eta}(\eta) = \overline{X(\eta, t)}$$

$$\lim_{T \rightarrow \infty} P\{|m_{X\eta}(\eta) - m_X(t)| < \varepsilon\} = 1$$

ceea ce implică anularea variantei variabilei aleatoare  $m_{X\eta}(\eta)$ .

Deoarece demonstrarea ergodicității este, în general, anevoioasă, adesea în practică este suficientă considerarea *ergodicității în raport cu media liniară* (de ordinul întâi), care poate fi numită *ergodicitate practică*.

Definiție (ergodicitate practică sau în raport cu media liniară): Un semnal aleator staționar se numește practic ergodic dacă varianta mediei temporale este nulă:

$$\text{var}[m_{X\eta}(\eta)] = \sigma_{m_{X\eta}}^2 = 0$$

Interpretarea fenomenului de ergodicitate practica (sau in raport cu media liniara) este imediata. Deoarece  $m_{X\eta}(\eta)$  este o variabila aleatoare obtinuta printr-un proces la limita, conditia din definitia anterioara poate fi rescrisa sub forma:

$$\lim_{T \rightarrow \infty} \text{var} \left[ \frac{1}{T} \int_{-T/2}^{T/2} X(\eta, t) dt \right] = 0$$


sau, daca se introduce o noua variabila aleatoare:

$$m_{X\eta}(\eta, t) = \left[ \frac{1}{T} \int_{-T/2}^{T/2} X(\eta, t) dt \right]$$

$$\lim_{T \rightarrow \infty} \text{var} m_{X\eta}(\eta, t) = 0 \quad \text{sau}$$

$$\lim_{T \rightarrow \infty} m_{X\eta}(\eta, t) = m_X$$

Considerând un șir de momente  $T_n \rightarrow \infty$ , fiecare dintre variabilele aleatoare  $m_{X\eta}(\eta, T_n)$  are media  $m_X$ , varianta tinzând la zero pentru  $n = \infty$  (fig. 1)



*Fig.1. Reprezentarea fenomenului de ergodicitate practica. Punctele indica valori ale variabilelor aleatoare  $m_{X\eta}(\eta, T_n)$  oscilând in jurul mediei  $m_X$ , varianta tinzând la zero pentru  $n \rightarrow \infty$ .*

Un criteriu de ergodicitate util este conținut in teorema următoare:

**Teorema (criteriul de ergodicitate practica):** Fie un semnal staionar in sens larg  $X(\eta, t)$  continuu in timp. Daca:

$$\lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T}^T \left( 1 - \frac{|\tau|}{T} \right) C_{XX}(\tau) d\tau = 0,$$

atunci semnalul  $X(\eta, t)$  este practic ergodic.

**Demonstratie:**

Din condiția de anulare a variantei mediei temporale liniare, rezulta:

$$\begin{aligned} \sigma_{m_{X\eta}}^2 &= E\{[m_{X\eta}(\eta) - m_X]^2\} = E\{[m_{X\eta}(\eta)]^2\} - (m_X)^2 \\ &= \lim_{T \rightarrow \infty} \frac{1}{T^2} \int_{-T/2}^{T/2} \int_{-T/2}^{T/2} X(\eta, v) X(\eta, u) dv du - (m_X)^2 \end{aligned}$$

cu schimbarea de variabile

$$v - u = \tau \Rightarrow v = u + \tau,$$

$$v = v,$$

se trece de la planul  $(v, u)$  la planul  $(v, \tau)$ . Domeniul de integrare in planul  $(v, u)$  din fig.2a se transforma in domeniul de integrare din fig.2b, limitele obtinandu-se din:

$$\begin{aligned} u = \frac{T}{2} &\Rightarrow v = \tau + \frac{T}{2}, \\ u = -\frac{T}{2} &\Rightarrow v = \tau - \frac{T}{2}. \end{aligned}$$

Cu aceasta, integrala dubla din ultima expresie a lui  $\sigma_{m_{X\eta}}^2$  se transforma in integrala simpla, deoarece elementul de suprafata  $(dvdu)$  din planul  $(v, u)$  se transforma in elementul  $(T - |\tau|)d\tau$  din planul  $(v, \tau)$ :

$$dvdu \rightarrow (T - |\tau|)d\tau$$




Fig.2 transformarea domeniului de integrare prin substitutia  $v - u = \tau$

Intr-adevar, aria paralelogramului din fig.2b se obtine prin scaderea suprafetei hasurate in fig.3b din suprafata hasurata din fig.3a.




Fig.3. Calculul elementului de suprafata in planul  $(v, \tau)$

Rezulta deci:

$$2 \int_{-T}^T \frac{T}{2} d\tau - \int_{-T}^T |\tau| d\tau = \int_{-T}^T (T - |\tau|) d\tau$$

in loc de 
$$\int_{-\frac{T}{2}}^{\frac{T}{2}} \int_{-\frac{T}{2}}^{\frac{T}{2}} dvdu$$

Teorema este demonstrata deoarece expresia lui  $\sigma_{m_{x\eta}}^2$  devine

$$\sigma_{m_{x\eta}}^2 = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T}^T \left(1 - \frac{|\tau|}{T}\right) C_{XX}(\tau) d\tau = 0$$

Un alt criteriu practic de recunoastere a ergodicitatii unui semnal aleator este dat de urmatorul corolar al teoremei precedente.

Corolar (alt criteriu de ergodicitate practica): Daca functia de autocovarianta a unui semnal aleator  $X(\eta, t)$  staionar tinde către zero

$$\lim_{\tau \rightarrow \infty} C_{XX}(\tau) = 0,$$

atunci semnalul  $X(\eta, t)$  este practic ergodic.

Demonstratie:

Pentru orice  $\varepsilon > 0$  se poate alege un  $\tau' > 0$  astfel incat:

$$|C_{XX}(\tau)| < \varepsilon, \quad \tau > \tau'.$$

Rezulta, atunci, pentru  $T > \tau'$ :

$$\left| \frac{1}{T} \int_{-T}^T \left(1 - \frac{|\tau|}{T}\right) C_{XX}(\tau) d\tau \right| \leq \frac{\varepsilon}{T} \int_{-T}^T \left(1 - \frac{|\tau|}{T}\right) d\tau = 2\varepsilon.$$

$$\text{Deci: } \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T}^T \left(1 - \frac{|\tau|}{T}\right) C_{XX}(\tau) d\tau = 0$$

si din teorema anterioara rezulta ca semnalul  $X(\eta, t)$  este practic ergodic.

- Prin urmare, pentru a verifica ergodicitatea unui semnal aleator in raport cu valoarea sa medie liniara, trebuie calculata functia sa de autocovarianta  $C_{XX}(\tau)$ , deci o valoare medie de ordinul al doilea.

In general, pentru verificarea ergodicitatii unei valori medii de ordinul  $k$  este necesar sa se dispună de o valoare medie de ordinul  $2k$ .

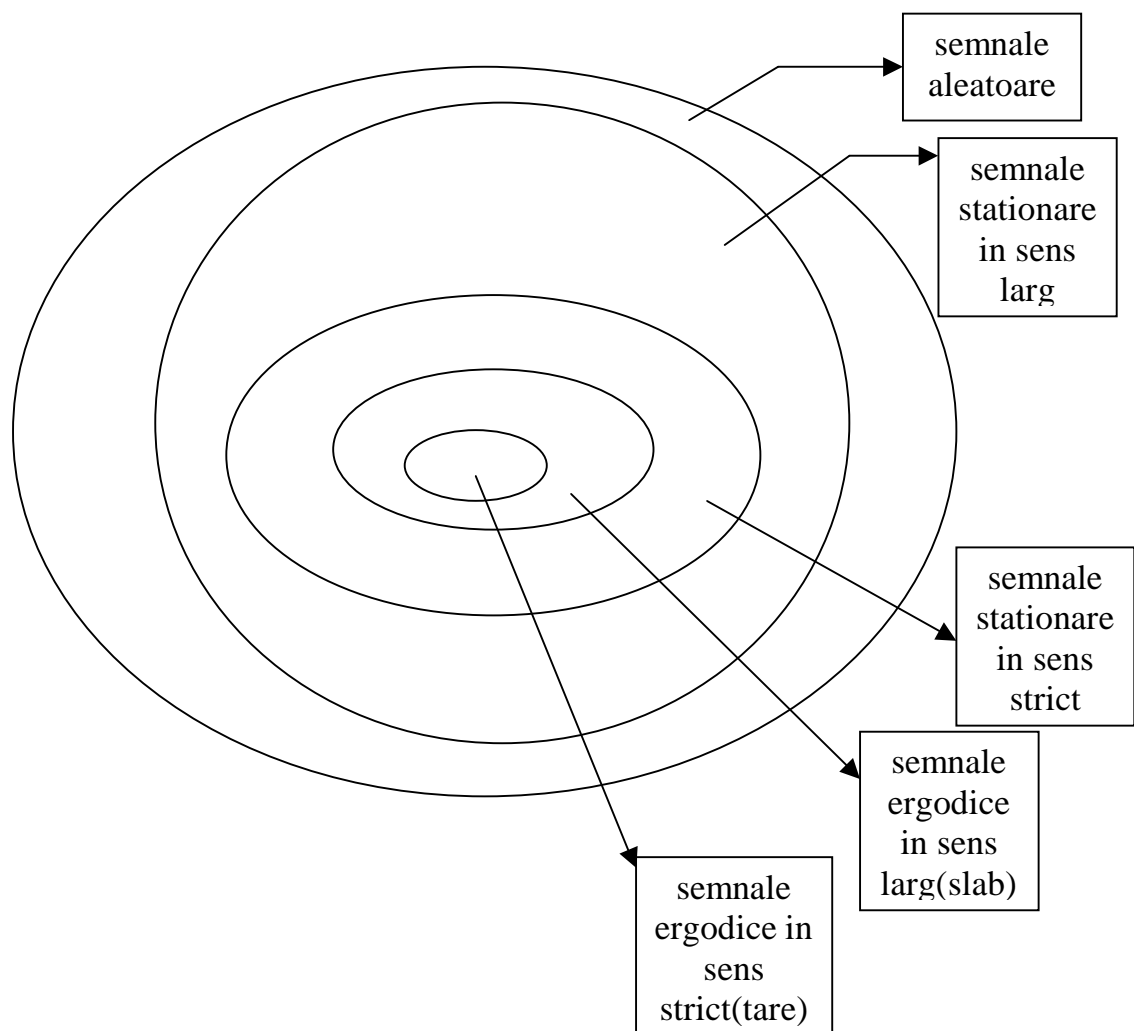


Demonstrarea ergodicitatii unui proces aleator este dificila si, ca atare, se efectuează numai in cazuri speciale, altminteri proprietatea de ergodicitate este doar presupusa.

- Ergodicitatea implica întotdeauna proprietatea de stationaritate ca o condiție necesara, dar insuficienta. Ierarhizarea claselor semnalelor staționare si ergodice este reprezentata in fig.4.

Observație:

Doua semnale aleatoare sunt *simultan ergodice* daca ambele sunt ergodice si daca momentele lor mutuale (corelația mutuala si covarianța) statistice sunt egale cu cele temporale.



*Fig.4. Ierarhizarea semnalelor aleatoare dupa proprietatile de stationaritate si ergodicitate.*

**Exemplu:**

Fie un semnal aleator sinusoidal cu amplitudinea, frecvența și faza aleatoare:

$$X(\eta, t) = A(\eta) \sin[\omega(\eta)t + \varphi(\eta)],$$

unde  $A(\eta)$ ,  $\omega(\eta)$  și  $\varphi(\eta)$  sunt variabile aleatoare independente;  $A(\eta)$  și  $\omega(\eta)$  au aceeași funcție de repartiție și iau valorile  $A \geq 0$  și, respectiv,  $\omega \geq 0$ .

În schimb,  $\varphi(\eta)$  are o repartiție uniformă,  $f(\varphi) = \frac{1}{2\pi}$ , în intervalul  $[0, 2\pi]$ .

Realizările particulare (traectoriile) semnalului aleator dat sunt semnale sinusoidale uzuale (fig.5).




Fig.5. Realizări particulare sinusoidale ale unui semnal aleator cu amplitudinea, frecvența și faza aleatoare.

- a) Acest semnal este staționar deoarece are repartițiile, respectiv densitățile de probabilitate, invariante la translațiile de timp:

$$\begin{aligned} f_n\{A \sin(\omega t_1 + \omega\tau + \varphi), \dots, A \sin(\omega t_n + \omega\tau + \varphi)\} = \\ = f_n\{A \sin(\omega t_1 + \varphi), \dots, A \sin(\omega t_n + \varphi)\} \end{aligned}$$

Dacă se notează:

$$\psi = \varphi + \alpha\tau,$$

$$\hat{\psi} = \psi + 2\pi k, \quad k = \text{int reg},$$

atunci ramane de demonstrat egalitatea:

$$f(A, \omega, \hat{\psi}) = f(A, \omega, \varphi),$$

unde s-au definit evenimentele simultane

$$A(\eta) \leq A, \omega(\eta) \leq \omega, \hat{\psi}(\eta) \leq \varphi.$$

Dar  $A, \omega, \varphi$  sunt variabile aleatoare independente, de unde rezulta si independenta v.a.  $A, \omega, \hat{\psi}$ . Egalitatea anterioara se reduce atunci la:

$$f(A)f(\omega)f(\hat{\psi}) = f(A)f(\omega)f(\varphi)$$

$$\text{sau la: } f(\hat{\psi}) = f(\varphi)$$

Dar  $\hat{\psi}$  se obtine din  $\varphi$  prin translatia cu  $\alpha\tau$  si reducere modulo  $2\pi$ . Deoarece repartitia lui  $\varphi$  este uniforma, aceasta nu se modifica prin translatie.

Prin urmare, ultima egalitate este demonstrata.

b) Media statistica liniara este constanta, semnalul fiind stationar; pentru  $\tau = -t$ , rezulta:

$$m_X^{(1)}(t) = m_X^{(1)}(t + \tau) = m_X^{(1)}(0),$$

$$m_X^{(1)}(0) = m_X^{(1)}\{A \sin \varphi\} = m_A^{(1)}\{A\}m_\varphi^{(1)}\{\sin \varphi\} = \overline{A} \frac{1}{2\pi} \int_0^{2\pi} \sin \varphi d\varphi = 0$$

c) Functia de autocovarianta, egala cu functia de autocorelatie deoarece valoarea medie este nula, se calculeaza dupa cum urmeaza:

$$\begin{aligned} C_{XX}(t, s) &= R_{XX}(t, s) = E[A^2 \sin(\omega t + \varphi) \sin(\omega s + \varphi)] = \\ &= \frac{1}{2} \{E[A^2 \cos \omega(t - s)] - E[A^2 \cos(\omega t + \omega s + 2\varphi)]\} \end{aligned}$$

Notand densitatea de probabilitate a lui  $\omega$  prin  $f(\omega)$ , rezulta:

$$E[A^2 \cos \omega(t - s)] = \overline{A^2} E[\cos \omega(t - s)] = \overline{A^2} \int_0^\infty f(\omega) \cos \omega(t - s) d\omega$$

Similar, se deduce:

$$\begin{aligned} E[A^2 \cos(\omega t + \omega s + 2\varphi)] &= E[A^2] E[\cos(\omega t + \omega s + 2\varphi)] = \\ &= \overline{A^2} E[\cos(\omega t + \omega s) E[\cos 2\varphi]] - \overline{A^2} E[\sin(\omega t + \omega s) E[\sin 2\varphi]] = 0 \end{aligned}$$

S-a tinut cont ca  $E[\cos 2\varphi] = E[\sin 2\varphi] = 0$

Datorita faptului ca  $\varphi$  este v.a. uniform repartizata pe intervalul  $[0, 2\pi]$ .

Rezulta, prin urmare:

$$C_{XX}(t,s) = C_{XX}(t-s) = \frac{1}{2} \overline{A^2} \int_0^{2\pi} f(\omega) \cos \omega(t-s) d\omega,$$

ceea ce confirma stationaritatea semnalului.

În cazul densității de probabilitate particulare de forma (distribuției Cauchy):

$$f(\omega) = \frac{2}{\pi} \frac{1}{1 + \omega^2} u(\omega),$$

unde  $u(\omega)$  este funcția treaptă unitate, se obține

$$C_{XX}(t) = C_{XX}(t,0) = R_{XX}(t,0) = \frac{1}{\pi} \overline{A^2} \int_0^{\infty} \frac{\cos \omega t}{1 + \omega^2} d\omega = \frac{1}{2} \overline{A^2} e^{-|t|}$$

Funcția de autocorelație este reprezentată în fig.6 și este tipică pentru un proces aleator staționar.




Fig.6. Funcția de autocorelație (autocovarianța) a semnalului  $X(\eta, t)$  sinusoidal cu amplitudine, frecvență și fază aleatoare.

## 12. Analiza spectrala a semnalelor aleatoare stationare in sens larg

### • Densitatea spectrala de putere

$$X(\eta, t) \Rightarrow X^\eta(t) \Rightarrow X_T^\eta(t)$$

$$\downarrow$$

$$\downarrow$$

$$\downarrow$$

proces realiz. particular. realizare trunchiat.

aleator a procesului a procesului, definita ca mai jos :

$$X_T^\eta(t) = \{X^\eta(t)\} \quad |t| \leq T/2$$

$$X_T^\eta(t) = 0, \quad \text{in rest}$$

$X_T^\eta(t)$  admite transformata Fourier :

$$X_T^\eta(\omega) = \int_{-\infty}^{\infty} X^\eta(t) \exp(-j\omega t) dt = \int_{-T/2}^{T/2} X^\eta(t) \exp(-j\omega t) dt$$

care este tot proces aleator. Energia normata (pe  $R = 1 \Omega$ ) este :

$$E_T^\eta = \int_{-\infty}^{\infty} [X_T^\eta(t)]^2 dt \xRightarrow{\text{Parseval}} \frac{1}{2\pi} \int_{-\infty}^{\infty} [X_T^\eta(\omega)]^2 d\omega$$

si este de asemenea proces aleator. Energia medie normata este :

$$\overline{E_T} = \int_{-\infty}^{\infty} \overline{[X_T^\eta(t)]^2} dt = \frac{1}{2\pi} \int_{-\infty}^{\infty} \overline{|X_T^\eta(\omega)|^2} d\omega$$

Puterea medie normata este :

$$\begin{aligned} P &= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\infty}^{\infty} \overline{[X_T^\eta(t)]^2} dt = \lim_{T \rightarrow \infty} \frac{1}{2\pi T} \int_{-\infty}^{\infty} \overline{|X_T^\eta(\omega)|^2} d\omega = \\ &= \frac{1}{2\pi} \int_{-\infty}^{\infty} \frac{1}{T} \overline{|X_T^\eta(\omega)|^2} d\omega = \frac{1}{2\pi} \int_{-\infty}^{+\infty} q_{XX}(\omega) d\omega \quad \text{unde} \end{aligned}$$

$$q_{XX}(\omega) = \lim_{T \rightarrow \infty} \frac{1}{T} \overline{|X_T^\eta(\omega)|^2} \quad \text{este densitatea spectrala de putere}$$

### • Teorema Wiener – Hincin

Teorema: pentru un semnal aleator stationar in sens larg, densitatea spectrala de putere  $q_{XX}(\omega)$  este transformata Fourier a functiei de autocorelatie  $R_{XX}(\tau)$  .

$$\begin{aligned}
& \left. \begin{aligned} q_{XX}(\omega) &= F\{R_{XX}(\tau)\} \\ R_{XX}(\tau) &= F^{-1}\{q_{XX}(\omega)\} \end{aligned} \right\} \begin{aligned} & q_{XX}(\omega) \xrightarrow{F^{-1}} R_{XX}(\tau) \\ & \xleftarrow{F} \end{aligned} \\
q_{XX}(\omega) &= \lim_{T \rightarrow \infty} \frac{1}{T} \overline{|X_T^\eta(\omega)|^2} = \lim_{T \rightarrow \infty} \frac{1}{T} \overline{[X_T^\eta(\omega)]^* \cdot X_T^\eta(\omega)} = \\
&= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\infty}^{\infty} X_T^\eta(t_1) \exp(j\omega t_1) dt_1 \int_{-\infty}^{\infty} X_T^\eta(t_2) \exp(-j\omega t_2) dt_2 = \\
&= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \overline{X_T^\eta(t_1) X_T^\eta(t_2) \exp(-j\omega(t_2 - t_1))} dt_1 dt_2 = \\
&= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2-T/2}^{T/2} \int_{-T/2}^{T/2} X_T^\eta(t_1) X_T^\eta(t_2) \exp(-j\omega(t_2 - t_1)) dt_1 dt_2 = \\
&= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2-T/2}^{T/2} \int_{-T/2}^{T/2} R_{XX}(t_1, t_2) \exp(-j\omega(t_2 - t_1)) dt_1 dt_2
\end{aligned}$$

Daca semnalul este stationar in sens larg,  $R_{XX}(t_1, t_2) = R_{XX}(t_2 - t_1)$

Daca se noteaza  $\varphi(t_2 - t_1) = R_{XX}(t_2 - t_1) \exp(-j\omega(t_2 - t_1))$  rezulta

$$q_{XX}(\omega) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2-T/2}^{T/2} \int_{-T/2}^{T/2} \varphi(t_2 - t_1) dt_2 dt_1$$

Cu schimbarea de variabila  $t_2 - t_1 = \tau$ ,

$$\begin{aligned}
q_{XX}(\omega) &= \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T}^T \varphi(\tau) [T - |\tau|] d\tau = \lim_{T \rightarrow \infty} \int_{-T}^T R_{XX}(\tau) \exp(-j\omega\tau) \left(1 - \frac{|\tau|}{T}\right) d\tau = \\
&= \int_{-\infty}^{\infty} R_{XX}(\tau) \exp(-j\omega\tau) d\tau = F\{R_{XX}(\tau)\}
\end{aligned}$$

**Densitatea spectrala de putere de interactiune (mutuala).**

	$X(\eta, t)$	$Y(\eta, t)$
	$\downarrow$	$\downarrow$
Fie doua semnale aleatoare:	$X_T^\eta(t)$	$Y_T^\eta(t)$
	$\downarrow$	$\downarrow$
	$X_T^\eta(\omega)$	$Y_T^\eta(\omega)$

$$q_{XY}(\omega) = \lim_{T \rightarrow \infty} \frac{1}{T} [X_T^\eta(\omega)]^* \cdot Y_T^\eta(\omega) = F\{R_{XY}(\tau)\}$$

$$q_{YX}(\omega) = \lim_{T \rightarrow \infty} \frac{1}{T} X_T^\eta(\omega) \cdot [Y_T^\eta(\omega)]^* = F\{R_{YX}(\tau)\}$$



• **Proprietatile densitatii spectrale de putere**

1.  $q_{XX}(\omega) = \lim_{T \rightarrow \infty} \frac{1}{T} \overline{|X_T(\omega)|^2} > 0, \quad \forall \omega: \text{este o functie pozitiv definita}$

2.  $q_{XX}(\omega) = q_{XX}(-\omega): \text{este o functie para}$

3.  $q_{XX}(\omega) = \text{este reala pentru } \forall \omega$

4.  $P = \frac{1}{2\pi} \int_{-\infty}^{\infty} q_{XX}(\omega) d\omega$  este puterea medie a semnalului



$p_{XX}(\omega)$  este densitatea spectrala de putere pentru  $\omega > 0$

$$P = \frac{1}{2\pi} \int_0^{\infty} p_{XX}(\omega) d\omega$$

$$p_{XX}(\omega) = 2q_{XX}(\omega) \cdot U(\omega)$$

$$U(\omega) = \begin{cases} 1, & \omega \geq 0 \\ 0, & \omega < 0 \end{cases}$$


• **Proprietatile densitatii spectrale de putere de interactiune si ale functiilor de intercorelatie**

$$q_{XY}(\omega) = q_{YX}(-\omega)$$

$$q_{XY}(\omega) = [q_{XY}(-\omega)]^*$$

$$R_{XY}(\tau) = R_{YX}(-\tau)$$

• **Proprietatile functiei de autocorelatie**



$$R_{XX}(t_1, t_2) = R_{XX}(t_2 - t_1) = R_{XX}(\tau) = E\{X(\eta, t_1) \cdot X(\eta, t_2)\}$$

$$R_{XX}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} q_{XX}(\omega) \exp(j\omega\tau) d\omega$$

$$1. \quad \lim_{\tau \rightarrow \infty} R_{XX}(\tau) = E\{X(\eta, t_1)\} \cdot E\{X(\eta, t_2)\} = (m_X)^2$$

$$2. \quad R_{XX}(0) = m_X^{(2)} = P$$

$$\lim_{\tau \rightarrow 0} R_{XX}(\tau) = E\{X(\eta, t) \cdot X(\eta, t)\} = E\{X^2(\eta, t)\} = m_X^{(2)}$$

$$\lim_{\tau \rightarrow 0} R_{XX}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} q_{XX}(\omega) d\omega = P$$

$$3. \quad \sigma_X^2 = m_X^{(2)} - (m_X)^2 = R_{XX}(0) - \lim_{\tau \rightarrow \infty} R_{XX}(\tau)$$

$$4. \quad R_{XX}(0) \geq R_{XX}(\tau) \quad \forall \tau: \text{ fctia de autocorelatie este maxima in } 0$$

$$\overline{[X(\eta, t) - X(\eta, t + \tau)]^2} \geq 0$$

$$\overline{X^2(\eta, t) + X^2(\eta, t + \tau) - 2X(\eta, t)X(\eta, t + \tau)} \geq 0$$

$$\Rightarrow 2\overline{X^2(\eta, t)} - 2\overline{X(\eta, t)X(\eta, t + \tau)} \geq 0$$

$$\Rightarrow R_{XX}(0) - R_{XX}(\tau) \geq 0$$

$$\Rightarrow R_{XX}(0) \geq R_{XX}(\tau), \quad \forall \tau$$



5.  $R_{XX}(\tau) = R_{XX}(-\tau)$  funcția de autocorelație este pară

$$R_{XX}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} q_{XX}(\omega) \exp(j\omega\tau) d\tau = \frac{1}{2\pi} \int_{-\infty}^{\infty} q_{XX}(\omega) \cos(\omega\tau) d\tau$$

6. funcția de autocorelație a unui semnal periodic este un semnal periodic de aceeași perioadă  $T_0 = 2\pi/\omega_0$

$$X(t) = \sum_{n=-\infty}^{\infty} C(n\omega_0) \exp(jn\omega_0 t)$$

$$P \stackrel{\text{Parseval}}{=} \sum_{n=-\infty}^{\infty} |C(n\omega_0)|^2$$

$$\Rightarrow q_{XX}(\omega) = 2\pi \sum_{n=-\infty}^{\infty} |C(n\omega_0)|^2 \cdot \delta(\omega - n\omega_0) \quad \text{un spectru de linii}$$

$$\Rightarrow R_{XX}(\tau) = F^{-1}\{q_{XX}(\omega)\} = \sum_{n=-\infty}^{\infty} |C(n\omega_0)|^2 \cdot \cos(n\omega_0 \tau)$$

### • Banda de frecvențe a semnalelor aleatoare

a) Semnale aleatoare trece-jos, al căror spectru se întinde între 0 și frecvența maximă  $f_{max}$  care se determină lățimea de bandă  $B$  a acestor semnale:  $B = f_{max}$ .

*Exemple:* semnale în banda de bază:

○ Sunet:

- de calitate telefonică, având  $f_{max} = 3,4$  kHz
- de calitate radio, având  $f_{max} = 7$  kHz
- de înaltă fidelitate (Hi-Fi), având  $f_{max} = 20$  kHz

○ Imagine:



- alb – negru, având  $f_{max} = 5,5$  MHz
- color, având  $f_{max} = 7,5$  MHz

○ Date:  $B = 0,7 f_T$ , unde  $f_T$  este frecvența de tact

b) Semnale aleatoare trece bandă care ocupă o bandă de frecvențe  $B$  în jurul unei frecvențe centrale  $f_c$

*Exemple:* semnale


modulate în amplitudine, semnale esantionate



c) Semnale aleatoare cu banda de frecvente echivalenta

$$2\pi B_{ech} \cdot q_{XX}(0) = \int_{-\infty}^{\infty} q_{XX}(\omega) d\omega$$

$$B_{ech} = \frac{1}{2\pi} \cdot \frac{\int_{-\infty}^{\infty} q_{XX}(\omega) d\omega}{q_{XX}(0)}$$



- **Timp de corelatie  $\tau_c$**


$$\tau_c \cdot R_{XX}(0) = \int_{-\infty}^{\infty} R_{XX}(\tau) d\tau$$

$$\tau_c = \frac{\int_{-\infty}^{\infty} R_{XX}(\tau) d\tau}{R_{XX}(0)}$$

Daca  $R_{XX}(\tau) = F^{-1}(q_{XX}(\omega))$

atunci

$$\tau_c = \frac{q_{XX}(0)}{\int_{-\infty}^{\infty} q_{XX}(\omega) d\omega} = \frac{1}{2\pi B_{ech}}$$



- **Funcția de coerenta** a doua semnale aleatoare  $X(\eta, t)$  si  $Y(\eta, t)$  poate preciza gradul de dependenta intre procese:

$$\rho_{XY}^2(\omega) = \frac{|q_{XY}(\omega)|^2}{q_{XX}(\omega) \cdot q_{YY}(\omega)}$$


pentru  $\rho_{XY}^2(\omega_0) = 0$  semnalele sunt incoerente la frecventa  $\omega_0$

pentru  $\rho_{XY}^2(\omega_0) = 1$  semnalele sunt coerente la frecventa  $\omega_0$

### 13. Exemple de funcții de autocorelație


a)  $R_{XX}(\tau) = A \cos \omega_0 \tau$

$$q_{XX}(\omega) = \frac{A}{2} [\delta(\omega - \omega_0) + \delta(\omega + \omega_0)]$$




b)  $R_{XX}(\tau) = \begin{cases} 1 - |\tau|/T, & \text{pentru } |\tau| < T \\ 0, & \text{pentru rest} \end{cases}$

$$q_{XX}(\omega) = T \cdot \left( \frac{\sin \omega \tau / 2}{\omega \tau / 2} \right)^2$$




c)  $R_{XX}(\tau) = A \exp(-\alpha |\tau|)$

$$q_{XX}(\omega) = \frac{2A\alpha}{\alpha^2 + (\omega)^2}$$




d)  $q_{XX}(\omega) = \frac{N_0}{2} \quad \forall \omega \text{ real} \quad B_{ech} \rightarrow \infty$

$$R_{XX}(\tau) = \frac{N_0}{2} \delta(\tau) \quad \tau_c \rightarrow 0$$




e)  $q_{XX}(\omega) = A \quad \forall |\omega| \leq \omega_0 \quad B_{ech} = \frac{\omega_0}{2\pi}$

$$R_{XX}(\tau) = \frac{A\omega_0}{\pi} \text{sinc } \omega_0 \tau \quad \tau_c = \tau_0 = \frac{\pi}{\omega_0}$$



f)  $q_{XX}(\omega) = A \quad \forall \mp f_c - \frac{B}{2} \leq \frac{\omega}{2\pi} \leq \mp f_c + \frac{B}{2}$

$$R_{XX}(\tau) = \frac{B}{2\pi} \cdot A \text{sinc } \frac{B\tau}{2} \cdot \cos 2\pi f_c \tau$$



## 14. Aplicații la funcția de corelație

### a) Detectia semnalelor slabe, acoperite de perturbatii

Fie un semnal aleator

$$\begin{array}{ccccc} X(\eta, t) & = & S(\eta, t) + & N(\eta, t) \\ \Downarrow & & \Downarrow & & \Downarrow \end{array}$$

semnal receptionat    semnal util    perturbatie


$S(\eta, t)$  si  $N(\eta, t)$ , fiind produse de surse diferite, sunt independente statistic, deci sunt decorelate si daca  $E\{N(\eta, t)\} = 0$ , sunt si ortogonale :

$$R_{SN}(\tau) = R_{NS}(\tau) = 0 \text{ de unde :}$$


$$R_{XX}(\tau) = E\{X(\eta, t) \cdot X(\eta, t + \tau)\} =$$

$$E\{[S(\eta, t) + N(\eta, t)] \cdot [S(\eta, t + \tau) + N(\eta, t + \tau)]\} =$$

$$R_{SS}(\tau) + R_{SN}(\tau) + R_{NS}(\tau) + R_{NN}(\tau) = R_{SS}(\tau) + R_{NN}(\tau)$$




$$\lim_{\tau \rightarrow \infty} R_{XX}(\tau) = R_{SS}(\tau)$$



### b) Masurarea vitezelor de deplasare

Exemplu: masurarea vitezei  $v$  a unui mediu mobil  $M$  fata de doua traductoare fixe  $T_1, T_2$ , situate la o distanta cunoscuta  $l$  unul de altul.



Functionare: se regleaza  $\tau$  pana cand  $R_{SS}(t_0 - \tau)$  este maxim. Atunci  $t_0 - \tau = 0$  sau  $t_0 = \tau = l/v \Rightarrow v = l/\tau$ . Se pot masura astfel viteze de deplasare ale laminatelor, vehiculelor, etc.

c) Determinarea continuitatii unui semnal aleator

Semnalul aleator stationar in sens larg  $X(\eta, t)$  este continuu, in sensul mediei patratice, daca :


$$\lim_{\tau \rightarrow 0} \overline{[X(\eta, t + \tau) - X(\eta, t)]^2} = 0$$

$$\Rightarrow \lim_{\tau \rightarrow 0} \overline{X^2(\eta, t + \tau) + X^2(\eta, t) - 2X(\eta, t + \tau) \cdot X(\eta, t)}$$

$$\Rightarrow \lim_{\tau \rightarrow 0} [2R_{XX}(0) - 2R_{XX}(\tau)] = 0 \Rightarrow \lim_{\tau \rightarrow 0} [R_{XX}(0) - R_{XX}(\tau)] = 0$$

deci daca functia sa de autocorelatie este continua in origine.


Obs.: structura generala a unui corelator, pentru semnale analogice ergodice, este data in fig. de mai jos:



unde  $R_{YX}(\eta, \tau) = \frac{1}{T} \int_{-T/2}^{T/2} X(\eta, t + \tau) Y(\eta, t) dt$

Pentru semnale digitale

$$R_{YX}(\eta, l) = \frac{1}{M} \sum_{k=0}^{M-1} X(\eta, k + l) Y(\eta, k)$$




## 15. Prelucrarea liniara a semnalelor aleatoare (filtrare)

### • Notiuni fundamentale

Se considera ca semnalele aleatoare  $x(t) = X_\eta(t) = X^\eta(t)$  trec prin sisteme liniare, invariante in timp si cauzale (SLITC), la care functia pondere respecta relatia:  $h(t) = 0, t < 0$

$$Y(\omega) = H(\omega) \cdot X(\omega)$$



$$y(t) = \int_{-\infty}^{\infty} x(t - \tau) h(\tau) d\tau$$

$$= \int_{-\infty}^{\infty} x(\tau) h(t - \tau) d\tau = [x * h](t)$$

$$\begin{aligned} q_{YY}(\omega) &= \lim_{T \rightarrow \infty} \frac{\overline{|Y_T(\omega)|^2}}{T} = \lim_{T \rightarrow \infty} \frac{\overline{|X_T(\omega) \cdot H(\omega)|^2}}{T} = |H(\omega)|^2 \lim_{T \rightarrow \infty} \frac{\overline{|X_T(\omega)|^2}}{T} = \\ &= |H(\omega)|^2 \cdot q_{XX}(\omega) = H(\omega) H^*(\omega) \cdot q_{XX}(\omega) \end{aligned}$$

$$\begin{aligned} E\{y(t)\} &= E\left\{ \int_{-\infty}^{\infty} x(t - \tau) h(\tau) d\tau \right\} = \int_{-\infty}^{\infty} \{E[x(t - \tau)]\} h(\tau) d\tau = \int_{-\infty}^{\infty} m_X(t - \tau) h(\tau) d\tau = \\ &= m_X \cdot \int_{-\infty}^{\infty} h(\tau) d\tau = m_X \cdot H(0) \end{aligned}$$

$$\begin{aligned} R_{YY}(t_1, t_2) &= E\{y(t_1) \cdot y(t_2)\} = E\left\{ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x(t_1 - \tau_1) h(\tau_1) d\tau_1 \cdot x(t_2 - \tau_2) h(\tau_2) d\tau_2 \right\} = \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} R_{XX}(t_1 - \tau_1, t_2 - \tau_2) h(\tau_1) h(\tau_2) d\tau_1 d\tau_2 \end{aligned}$$

$$R_{YY}(t_1 - t_2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} R_{XX}(t_1 - \tau_1 - t_2 + \tau_2) h(\tau_1) h(\tau_2) d\tau_1 d\tau_2$$

$$\begin{cases} R_{YY}(\tau) = R_{XX}(\tau) * h(\tau) * h(-\tau) \\ q_{YY}(\omega) = q_{XX}(\omega) \cdot H(\omega) H^*(\omega) \end{cases} \quad \begin{cases} F[R_{YY}(\tau)] = q_{YY}(\omega) \\ F^{-1}[q_{YY}(\omega)] = R_{YY}(\tau) \end{cases}$$

$$R_{YY}(\tau) = \mathcal{F}^{-1}\{q_{YY}(\omega)\} = \frac{1}{2\pi} \int_{-\infty}^{\infty} q_{XX}(\omega) \cdot |H(\omega)|^2 \exp(j\omega\tau) d\omega$$

$$E\{y^2(t)\} = R_{YY}(0) = \frac{1}{2\pi} \int_{-\infty}^{\infty} q_{XX}(\omega) \cdot |H(\omega)|^2 d\omega$$

$$q_{XY}(\omega) = q_{XX}(\omega) \cdot H(\omega)$$

$$\Rightarrow R_{XY}(\tau) = R_{XX}(\tau) * h(\tau)$$

$$q_{YX}(\omega) = q_{XX}(\omega) \cdot H^*(\omega)$$

$$\Rightarrow R_{YX}(\tau) = R_{XX}(\tau) * h(-\tau)$$

$$q_{YY}(\omega) = q_{YX}(\omega) \cdot H(\omega) = q_{XY}(\omega) \cdot H^*(\omega) \Rightarrow R_{YY}(\tau) = R_{XX}(\tau) * h(-\tau) * h(\tau)$$

$$q_{XX}(\omega) \cdot H(\omega) H^*(\omega) = q_{YY}(\omega)$$

- Trecerea zgomotului alb prin sisteme liniare

Pentru zgomot alb:


$$q_{XX}(\omega) = \frac{N_0}{2}, \quad \forall \omega \in \mathfrak{R}$$

$$R_{XX}(\tau) = \frac{N_0}{2} \delta(\tau)$$

$$m_X = 0$$

coeficientul de autocorelatie este :

$$\rho_{XX}(\tau) = \frac{R_{XX}(\tau)}{R_{XX}(0)} = 0$$



Pentru zg. alb

Pentru semnalul de la iesire :

$$q_{YY}(\omega) = \frac{N_0}{2} \cdot A^2(\omega)$$

$$R_{YY}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} q_{YY}(\omega) \exp(j\omega\tau) d\omega = \frac{N_0}{4\pi} \int_{-\infty}^{\infty} A^2(\omega) \exp(j\omega\tau) d\omega$$


$$m_Y = H(0) \cdot m_X = 0$$

coeficientul de autocorelatie este :

$$\rho_{YY}(\tau) = \frac{R_{YY}(\tau)}{R_{YY}(0)} = \frac{\frac{N_0}{4\pi} \int_{-\infty}^{\infty} A^2(\omega) \exp(j\omega\tau) d\omega}{\frac{N_0}{4\pi} \int_{-\infty}^{\infty} A^2(\omega) d\omega} \neq 0$$

Obs.: orice sistem liniar produce un semnal de iesire cu un grad de corelare mai mare decat gradul de corelare al semnalului de intrare.

- Determinarea lui  $h(t)$  pentru SLITC, prin metoda de autocorelatie



Pentru zgomot alb la intrare:

$$R_{XX}(\tau) = \frac{N_0}{2} \delta(\tau), \quad \forall \omega \in \Re$$

$$R_{XY}(\tau) = R_{XX}(\tau) * h(\tau) = \int_{-\infty}^{\infty} h(u) R_{XX}(\tau - u) du = \frac{N_0}{2} h(\tau)$$

$$R_{XY}(\tau) = \int_{-\infty}^{\infty} h(u) \frac{N_0}{2} \delta(\tau - u) du = \frac{N_0}{2} h(\tau)$$

$$\Rightarrow h(\tau) = \frac{2}{N_0} \cdot R_{XY}(\tau)$$

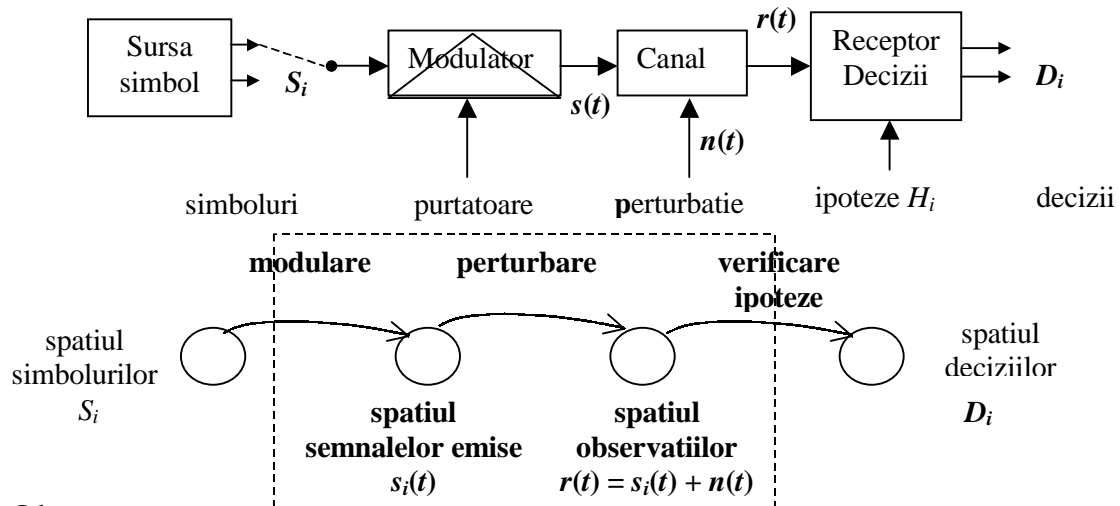
unde  $R_{XY}(\tau)$  se obtine cu montajul de mai sus



## Detectia semnalelor

Detectia semnalelor presupune determinarea prezentei sau absentei unui semnal cu semnificatie (exemple: ecul in radar sau in sonar, la transmisii de date prezenta sau absenta unor simboluri dintr-un alfabet finit si cunoscut ).


### 1. Modelul sistemelor de detectie a semnalelor



Obs.:

- la receptie se verifica toate ipotezele relative la simbolurile  $S_i$  si daca ipoteza  $H_i$  este adevarata se ia decizia  $D_i$  ca semnalul receptionat  $r(t)$  corespunde simbolului  $S_i$ .
- ipotezele pot fi simple ( $S_i \Leftrightarrow s_i(t)$  ca punct in spatiul semnalelor) sau compuse ( $S_i \Leftrightarrow s_i(t)$  ca domeniu in spatiul semnalelor)
- observatiile pot fi discrete (esantioane ale  $r(t)$ ) sau continue (pentru intregul semnal  $r(t)$ ).

### 2. Detectie binara ( $i = 0,1$ ) cu observatii discrete (o singura observatie pe simbol)



În detectia binara avem doua simboluri ( $S_0$  si  $S_1$ ) si doua ipoteze ( $H_0$  si  $H_1$ ):

$H_0$ : a fost transmis 0 ( $S_0$ )

$H_1$ : a fost transmis 1 ( $S_1$ )

Se urmareste gasirea unui criteriu de stabilire a ipotezei corecte, pe baza unei singure observatii asupra  $R$ . Se presupun cunoscute densitatile de probabilitate ale  $R$  in cele doua ipoteze:  $f_{R|H_0}(r|H_0)$  și  $f_{R|H_1}(r|H_1)$ . Dacă  $P(H_i|r)$  cu  $i = 0,1$

reprezinta probabilitatea ipotezei  $H_i$  la receptia  $r$ :

se alege  $H_0$  dacă  $P(H_0|r) > P(H_1|r)$

se alege  $H_1$  dacă  $P(H_1|r) > P(H_0|r)$  sau, concis :

$$\frac{P(H_1|r)}{P(H_0|r)} \underset{H_0}{\overset{H_1}{>}} 1$$

- Criteriul de decizie MAP (maximum a posteriori probability). Criteriul de decizie duce la partiția spațiului observațiilor în două regiuni  $R_0$  și  $R_1$  și se alege  $H_0$  dacă  $r$  este conținut în  $R_0$  și  $H_1$  dacă  $r$  este conținut în  $R_1$ . Cu regula Bayes se poate scrie:

$$P(H_i | r) = \frac{f_{R|H_i}(r | H_i)P(H_i)}{f_R(r)} \text{ și atunci criteriul de}$$

mai sus se rescrie :

$$\frac{f_{R|H_1}(r | H_1)P(H_1)}{f_{R|H_0}(r | H_0)P(H_0)} \underset{H_0}{\overset{H_1}{>}} 1 \text{ sau :}$$


$$\frac{f_{R|H_1}(r | H_1)}{f_{R|H_0}(r | H_0)} \underset{H_0}{\overset{H_1}{>}} \frac{P(H_0)}{P(H_1)} \text{ sau :}$$

$$\Lambda(r) \underset{H_0}{\overset{H_1}{>}} K$$

daca se notează raportul de plauzibilitate  $\Lambda(r)$

si pragul testului  $K$  cu :

$$\Lambda(r) = \frac{f_{R|H_1}(r | H_1)}{f_{R|H_0}(r | H_0)} \quad K = \frac{P(H_0)}{P(H_1)}$$



Din cauza zgomotului se pot lua decizii eronate. Pot fi urmatoarele situatii:

- a) se decide  $D_0$  cand  $H_0$  este adevarat
- b) se decide  $D_1$  cand  $H_1$  este adevarat
- c) se decide  $D_0$  cand  $H_1$  este adevarat
- d) se decide  $D_1$  cand  $H_0$  este adevarat

primele doua decizii sunt corecte iar ultimele doua sunt eronate. Eroarea de tip c) se numeste eroare de pierdere (miss) si are

probabilitatea  $P_M = P(D_0 | H_1)$ . Eroarea de tip d) se numeste alarma falsa (false alarm) si are probabilitatea  $P_F = P(D_1 | H_0)$ . Ca masura a performantei sistemului se alege probabilitatea medie de eroare :

$$P_e = P(H_0)P(D_1 | H_0) + P(H_1)P(D_0 | H_1)$$

- Criteriul de decizie Bayes

Acest criteriu tine cont de “costurile” deciziilor in procesul de detectie binara. In acest proces apar perechi  $(D_i, H_j)$ . Fiecarei perechi  $i$  se poate asocia un cost  $C_{ij}$ . Criteriul de decizie Bayes minimizeza costul mediu. Costul mediu se defineste cu relatia:

$$\bar{C} = \sum_{i=0,1} \sum_{j=0,1} C_{ij} P(D_i, H_j) = \sum_{i=0,1} \sum_{j=0,1} C_{ij} P(H_j) P(D_i | H_j)$$

$$\begin{aligned} \bar{C} &= C_{00}P(D_0 | H_0)P(H_0) + C_{10}P(D_1 | H_0)P(H_0) + \\ &+ C_{01}P(D_0 | H_1)P(H_1) + C_{11}P(D_1 | H_1)P(H_1) = \\ &= C_{00}P(H_0) \int_{R_0} f_{R|H_0}(r | H_0) dr + C_{10}P(H_0) \int_{R_1} f_{R|H_0}(r | H_0) dr + \\ &+ C_{01}P(H_1) \int_{R_0} f_{R|H_1}(r | H_1) dr + C_{11}P(H_1) \int_{R_1} f_{R|H_1}(r | H_1) dr \end{aligned}$$

se face prezumția rezonabilă că decizia incorectă costă mai mult decât cea corectă :

$$C_{10} > C_{00} \text{ si } C_{01} > C_{11}$$

si se face uz de faptul ca  $R_1 \cup R_0 = (-\infty, \infty)$  si  $R_1 \cap R_0 = \emptyset$  si atunci :

$$\begin{aligned} \bar{C} &= C_{10}P(H_0) + C_{11}P(H_1) + \int_{R_0} \{ [P(H_1)(C_{01} - C_{11})f_{R|H_1}(r | H_1)] - \\ &[P(H_0)(C_{10} - C_{00})f_{R|H_0}(r | H_0)] \} dr \end{aligned}$$

Cea mai mica valoare a costului mediu se obtine cand integrandul ecuatiei de mai sus este negativ pentru toate valorile lui  $r \in R_0$ . Se poate accepta ipoteza  $H_0$  daca:

$$P(H_1)(C_{01} - C_{11})f_{R|H_1}(r|H_1) < P(H_0)(C_{10} - C_{00})f_{R|H_0}(r|H_0)$$


sau concis :

$$\Lambda(r) = \frac{f_{R|H_1}(r|H_1)}{f_{R|H_0}(r|H_0)} \underset{H_0}{\overset{H_1}{>}} \frac{P(H_0)(C_{10} - C_{00})}{P(H_1)(C_{01} - C_{11})} = K$$

Se vede ca pentru  $C_{10} - C_{00} = C_{01} - C_{11}$ , criteriul Bayes devine criteriul MAP.

Se poate arata ca daca:  $C_{00} = C_{11} = 0$  si  $C_{10} = C_{01} = 1$ , atunci criteriul Bayes minimizeaza probabilitatea deciziilor eronate.

### 3. Detectia binara ( $i = 0, 1$ ) cu observatii multiple pe simbol (daca $r > 0 \Rightarrow 1$ , daca $r < 0 \Rightarrow 0$ )




Daca receptorul observa  $N$  esantioane ale  $r(t)$  in intervalul  $(0, T)$ , notate  $r_1, r_2, \dots, r_N$ , se defineste vectorul

$$\vec{r} = [r_1, r_2, \dots, r_N]^T \text{ ca si densitatile de probabilitate :}$$

$$f(r_1, r_2, \dots, r_N / H_0) = f_{\vec{R}|H_0}(\vec{r} / H_0)$$

$$f(r_1, r_2, \dots, r_N / H_1) = f_{\vec{R}|H_1}(\vec{r} / H_1)$$



Se urmareste gasirea unor decizii corecte, pe baza mai multor observatii asupra  $\vec{R}$ . Se presupun cunoscute densitatile de probabilitate ale  $\vec{R}$  in cele doua ipoteze:

$$f_{\vec{R}|H_0}(\vec{r} | H_0) \text{ si } f_{\vec{R}|H_1}(\vec{r} | H_1).$$

Criteriile de decizie deduse pentru o singura observatie se pot rescrie pentru  $N$  observatii, dupa cum urmeaza:

$$\Lambda(\vec{r}) \underset{H_0}{\overset{H_1}{\geq}} K$$

unde pentru MAP :

$$\Lambda(\vec{r}) = \frac{f_{\vec{R}|H_1}(\vec{r} | H_1)}{f_{\vec{R}|H_0}(\vec{r} | H_0)} \quad K = \frac{P(H_0)}{P(H_1)}$$

pentru plauzibilitate maxima :

$$\Lambda(\vec{r}) = \frac{f_{\vec{R}|H_1}(\vec{r} | H_1)}{f_{\vec{R}|H_0}(\vec{r} | H_0)} \quad K = 1$$

pentru Bayes :

$$\Lambda(\vec{r}) = \frac{f_{\vec{R}|H_1}(\vec{r} | H_1)}{f_{\vec{R}|H_0}(\vec{r} | H_0)} \quad K = \frac{P(H_0)}{P(H_1)} \cdot \frac{C_{10} - C_{00}}{C_{01} - C_{11}}$$

pentru Neyman - Pearson :

$$\Lambda(\vec{r}) = \frac{f_{\vec{R}|H_1}(\vec{r} | H_1)}{f_{\vec{R}|H_0}(\vec{r} | H_0)} \quad K \text{ se alege din conditia } P_F \leq \alpha$$

Daca se noteaza cu

$f_{R_i|H_0}(r_i | H_0)$  si  $f_{R_i|H_1}(r_i | H_1)$  densitatile de probabilitate ale observatiei  $r_i$  in ipotezele  $H_0, H_1$  si daca observatiile sunt statistic independente, avem :

$$f_{\vec{R}|H_0}(\vec{r} | H_0) = \prod_{i=1}^N f_{R_i|H_0}(r_i | H_0)$$

$$f_{\vec{R}|H_1}(\vec{r} | H_1) = \prod_{i=1}^N f_{R_i|H_1}(r_i | H_1)$$

*Exemplu:* detectia a doua semnale de forma cunoscuta

$$s_0(t) = a_0 s(t) \quad 0 \leq t \leq T$$

$$s_1(t) = a_1 s(t) \quad 0 \leq t \leq T$$

$$r(t) = \vec{a}s(t) + n(t) \quad \vec{a} = \begin{cases} a_0 \Leftarrow H_0 \\ a_1 \Leftarrow H_1 \end{cases}$$

Se presupune ca zgomotul este gaussian, de valoare medie nula si de varianță  $\sigma^2$ .

Densitatea de probabilitate pentru un esantion de semnal receptionat este:

$$f_{R_i|H_0}(r_i | H_0) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(r_i - a_0s_i)^2\right] \Leftarrow H_0$$

$$f_{R_i|H_1}(r_i | H_1) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(r_i - a_1s_i)^2\right] \Leftarrow H_1$$

densitatea de probabilitate pentru vectorul receptionat este :

$$f_{\vec{R}|H_0}(\vec{r} | H_0) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^N \prod_{i=1}^N \exp\left[-\frac{1}{2\sigma^2}(r_i - a_0s_i)^2\right] \Leftarrow H_0$$

$$f_{\vec{R}|H_1}(\vec{r} | H_1) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^N \prod_{i=1}^N \exp\left[-\frac{1}{2\sigma^2}(r_i - a_1s_i)^2\right] \Leftarrow H_1$$

sau :

$$f_{\vec{R}|H_0}(\vec{r} | H_0) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^N \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^N (r_i - a_0s_i)^2\right] \Leftarrow H_0$$

$$f_{\vec{R}|H_1}(\vec{r} | H_1) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^N \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^N (r_i - a_1s_i)^2\right] \Leftarrow H_1$$

raportul de plauzibilitate este :

$$\Lambda(\vec{r}) = \frac{f_{\vec{R}|H_1}(\vec{r} | H_1)}{f_{\vec{R}|H_0}(\vec{r} | H_0)} = \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^N [(r_i - a_1s_i)^2 - (r_i - a_0s_i)^2]\right\}$$

$$\ln \Lambda(\vec{r}) = \frac{1}{2\sigma^2} \sum_{i=1}^N [(r_i - a_1s_i)^2 - (r_i - a_0s_i)^2] =$$



$$= \frac{1}{2\sigma^2} \left[ (a_0 - a_1) \left( -2 \sum_{i=1}^N r_i s_i + (a_0 + a_1) \sum_{i=1}^N s_i^2 \right) \right]$$

Criteriul plauzibilitatii maxime se poate scrie :

$$\ln \Lambda(\vec{r}) \underset{H_0}{\overset{H_1}{>}} \ln K = \ln 1 = 0$$

$$\sum_{i=1}^N r_i s_i \underset{H_0}{\overset{H_1}{>}} \frac{a_0 + a_1}{2} \sum_{i=1}^N s_i^2$$

pentru  $a_0 = 0, a_1 = 1, s_i = s$

$$\frac{1}{N} \sum_{i=1}^N r_i \underset{H_0}{\overset{H_1}{>}} \frac{s}{2} \quad \text{si daca } N=1 \quad r \underset{H_0}{\overset{H_1}{>}} \frac{s}{2}$$

pentru  $a_0 = -1, a_1 = 1, s_i = s$

$$\frac{1}{N} \sum_{i=1}^N r_i \underset{H_0}{\overset{H_1}{>}} 0 \quad \text{si pentru } N=1: \quad r \underset{H_0}{\overset{H_1}{>}} 0$$

Probabilitatea de eroare este :

$$P_e = P(D_0, H_1) + P(D_1, H_0) =$$

$$P(H_1) \int_{R_0} f_{R|H_1}^-(r | H_1) dr + P(H_0) \int_{R_1} f_{R|H_0}^-(r | H_0) dr$$

Observatie: Desi problema de detectie pe care ne-am propus sa o solutionam este formulata pentru un spatiu multidimensional, decizia se ia dupa o singura coordonata, care este, pentru cazul

general:  $\sum_{i=1}^N r_i s_i$ , iar pentru cazurile particulare mentionate


$$m_R = \frac{1}{N} \sum_{i=1}^N r_i$$

Aceasta unica coordonata dupa care se poate lua decizia se numeste “Statistica suficienta”.

#### 4. Detectie binara cu observatii multiple in ipoteza compusa

In ipoteza compusa, simbolului  $S_i$  ii corespunde in spatiul semnalului nu un punct  $s_i(t)$  ci un domeniu  $\Sigma_i$ .

*Exemplu:* Semnal de amplitudine variabila



$$H_0 \Rightarrow r(t) = s_0(t, \theta) + n(t) = n(t)$$

$$H_1 \Rightarrow r(t) = s_1(t, \theta) + n(t)$$

unde  $\theta$  este un parametru care ia valori in domeniul  $\Pi = (\theta_m, \theta_M)$

in timp ce semnalul  $s_1(t, \theta)$  este cuprins in domeniul  $\Sigma_1$

$$P\{\vec{s}_1 \in \Sigma_1\} = P\{\theta \in \Pi\}$$

$$f_{\vec{R}|H_1}(\vec{r} | H_1) = f_{\vec{R}|\theta}(\vec{r} | \theta)$$

$$\begin{aligned} f_{\vec{R}|H_1}(\vec{r} | H_1) &= f_{\vec{R}|H_1}(\vec{r} | \vec{s}_1 \in \Sigma_1) = f_{\vec{R}|\theta}(\vec{r} | \theta \in \Pi) = \int_{\Pi} f_{\vec{R}|\theta}(\vec{r}, \theta) d\theta = \\ &= \int_{\Pi} f_{\vec{R}|\theta}(\vec{r} | \theta) f_{\Theta}(\theta) d\theta \end{aligned}$$

Raportul de plauzibilitate este :

$$\Lambda(\vec{r}) = \frac{f_{\vec{R}|H_1}(\vec{r} | H_1)}{f_{\vec{R}|H_0}(\vec{r} | H_0)} = \frac{\int_{\Pi} f_{\vec{R}|\theta}(\vec{r} | \theta) f_{\Theta}(\theta) d\theta}{f_{\vec{R}|H_0}(\vec{r} | H_0)}$$

Pentru cazul particular al unui semnal de amplitudine variabila, cu amplitudinile uniform distribuite:

$$f_{\Theta}(\theta) = \frac{1}{\theta_M - \theta_m}$$

$$f_{\vec{R}|\theta}(\vec{r} | \theta) = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^N \prod_{i=1}^N \exp\left( -\frac{(r_i - \theta)^2}{2\sigma^2} \right)$$

$$f_{\vec{R}|H_0}(\vec{r} | H_0) = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^N \prod_{i=1}^N \exp\left( -\frac{(r_i)^2}{2\sigma^2} \right)$$

$$\Lambda(\vec{r}) = \frac{\frac{1}{\theta_M - \theta_m} \int_{\theta_m}^{\theta_M} \exp\left( -\frac{\sum_{i=1}^N (r_i - \theta)^2}{2\sigma^2} \right) d\theta}{\exp\left( -\frac{\sum_{i=1}^N r_i^2}{2\sigma^2} \right)} \quad \text{iar pt. } N=1:$$

$$\Lambda(\vec{r}) = \frac{\frac{1}{\theta_M - \theta_m} \int_{\theta_m}^{\theta_M} \exp\left( -\frac{(r - \theta)^2}{2\sigma^2} \right) d\theta}{\exp\left( -\frac{(r)^2}{2\sigma^2} \right)}$$

daca se noteaza :

$$F(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x \exp\left( -\frac{1}{2}u^2 du \right); \quad x = \frac{\theta - r}{\sigma} \quad \text{atunci raportul devine :}$$

$$\Lambda(\vec{r}) = \frac{\sqrt{2\pi\sigma^2}}{\theta_M - \theta_m} \exp\left( \frac{n^2}{2\sigma^2} \right) \cdot \left[ F\left( \frac{\theta_M - r}{\sigma} \right) - F\left( \frac{\theta_m - r}{\sigma} \right) \right]$$

iar daca pragul testului este  $K = 1$ , atunci testul Bayes este :

$$\frac{\sqrt{2\pi\sigma^2}}{\theta_M - \theta_m} \exp\left( \frac{n^2}{2\sigma^2} \right) \cdot \left[ F\left( \frac{\theta_M - r}{\sigma} \right) - F\left( \frac{\theta_m - r}{\sigma} \right) \right] \underset{H_0}{\overset{H_1}{\geq}} 1$$

## 5. Detectia secventiala

Daca este necesar sa reducem timpul de decizie, se lucreaza cu un numar  $m$  de observatii variabil, cautandu-se reducerea acestuia.

Pentru vectorul  $\vec{r}_m = (r_1, \dots, r_m)$  raportul de plauzibilitate este :

$$\Lambda(\vec{r}_m) = \frac{f_{\vec{R}_m|H_1}(\vec{r}_m | H_1)}{f_{\vec{R}_m|H_0}(\vec{r}_m | H_0)}$$

Algoritmul de testare este :

a) pentru prima observatie  $m = 1$ ,  $\vec{r}_m = \vec{r}_1$ , se calculeaza  $\Lambda(\vec{r}_1)$ , care se compara cu doua praguri  $A, B$  cu  $A > B$  :

- daca  $\Lambda(\vec{r}_1) \geq A \Rightarrow D_1$
- daca  $\Lambda(\vec{r}_1) \leq B \Rightarrow D_0$
- daca  $B < \Lambda(\vec{r}_1) < A \Rightarrow$  nu se ia decizie si se trece la a doua obsevare  $\vec{r}_2$

b) se calculeaza si se testeaza  $\Lambda(\vec{r}_2)$ ; daca din nou nu se ia nici o decizie se calculeaza  $\Lambda(\vec{r}_3)$  s. a. m. d. pana cand  $\Lambda(\vec{r}_m) \geq A \Rightarrow D_1$  sau  $\Lambda(\vec{r}_1) \leq B \Rightarrow D_0$

Pentru determinarea  $A, B$  se procedeaza astfel :

- daca se ia decizia  $D_1$  avem :

$$\Lambda(\vec{r}_m) = \frac{f_{\vec{R}_m|H_1}(\vec{r}_m | H_1)}{f_{\vec{R}_m|H_0}(\vec{r}_m | H_0)} \geq A \quad \text{sau} \quad f_{\vec{R}_m|H_1}(\vec{r}_m | H_1) \geq A f_{\vec{R}_m|H_0}(\vec{r}_m | H_0)$$

- daca se ia decizia  $D_0$  avem:

$$\Lambda(\overrightarrow{r_m}) = \frac{f_{\overrightarrow{R_m}|H_1}(\overrightarrow{r_m} | H_1)}{f_{\overrightarrow{R_m}|H_0}(\overrightarrow{r_m} | H_0)} \leq B \quad \text{sau} \quad f_{\overrightarrow{R_m}|H_1}(\overrightarrow{r_m} | H_1) \leq B f_{\overrightarrow{R_m}|H_0}(\overrightarrow{r_m} | H_0)$$

daca  $R_1$  cuprinde observatiile  $\overrightarrow{r_m}$  carora le corespunde  $D_1$  :

$$\int_{R_1} f_{\overrightarrow{R_m}|H_1}(\overrightarrow{r_m} | H_1) dR_m \geq A \int_{R_1} f_{\overrightarrow{R_m}|H_0}(\overrightarrow{r_m} | H_0) dR_m \quad \text{sau} \quad P_D \geq A P_F$$

de unde :

$$A \leq \frac{P_D}{P_F}$$

daca  $R_0$  cuprinde observatiile  $\overrightarrow{r_m}$  carora le corespunde  $D_0$  :

$$\int_{R_0} f_{\overrightarrow{R_m}|H_1}(\overrightarrow{r_m} | H_1) dR_m \leq B \int_{R_0} f_{\overrightarrow{R_m}|H_0}(\overrightarrow{r_m} | H_0) dR_m \quad \text{sau} \quad P_M \leq B(1 - P_F)$$

de unde :

$$B \geq \frac{P_M}{1 - P_F}$$

in cele de mai sus reamintim ca :

$P_D \rightarrow$  probabilitatea de detectie

$P_F \rightarrow$  probabilitatea deciziei eronate, de alarma falsa (prob. deciziei  $D_1$  cand sursa a emis  $S_0$ )

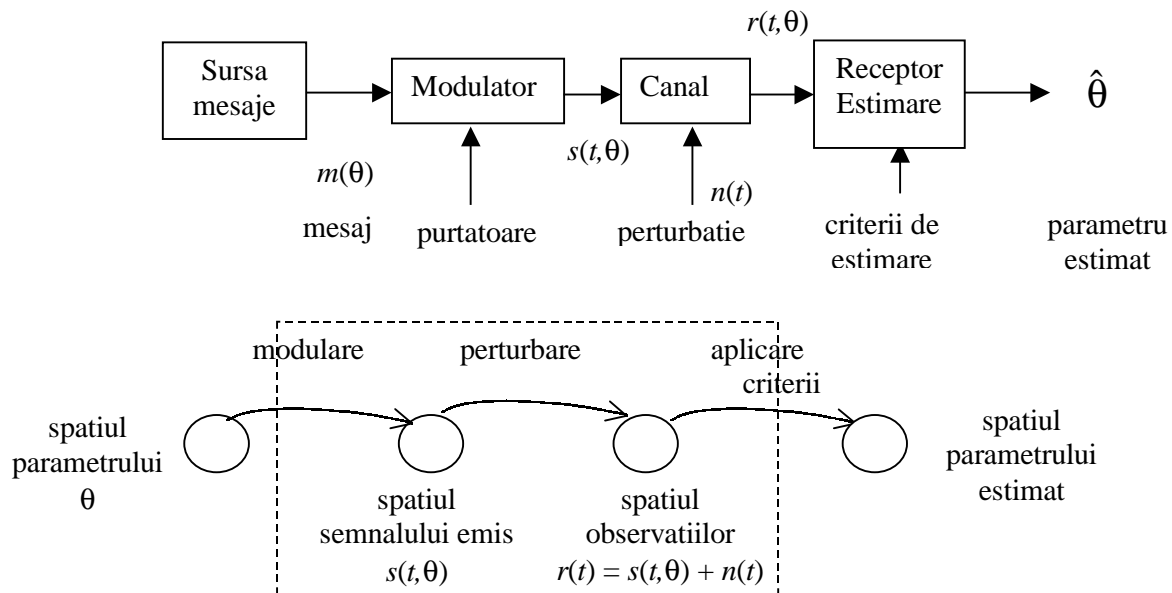
$P_M \rightarrow$  probabilitatea deciziei eronate, de pierderea tintei (prob. deciziei  $D_0$  cand sursa a emis  $S_1$ )

# Estimarea parametrilor semnalului

## 1. Introducere

Prin estimare se determina valoarea estimata  $\hat{\theta}$  a unui parametru  $\theta$  (purtaor de informatie) al semnalului afectat de perturbatie.

Schema bloc care modeleaza procesul de estimare a unui parametru si graful prelucrarii semnalelor sunt date mai jos.



*Exemple de aplicatii:*

- in receptia semnalelor: estimarea intarzierilor, a amplitudinilor de semnal, a deviatiilor de frecventa;
- in sisteme de comunicatii: estimarea functiilor de transfer, a functiilor pondere, a rapoartelor semnal / zgomot in canale de comunicatii;
- in sisteme de masura si comanda la distanta: estimarea marimii comandate (acceleratie, viteza, pozitie, temperatura, debit, etc)
- in prelucrari de semnale: estimarea unor parametri statistici ai semnalului (medii, variante)

Obs.: in aceste aplicatii se estimeaza parametri continui sau discreti, constanti sau variabili in timp; estimarea parametrilor discreti face legatura cu domeniul detectiei semnalelor (deciziei statistice) iar estimarea parametrilor variabili in timp face legatura cu estimarea formei semnalelor. Estimarea se poate face prin observare discreta sau prin observare continua.

## 2. Observarea discreta a unui parametru aleator

Semnalul receptionat este:

$$r(t) = s(t, \theta) + n(t)$$

unde  $\theta$  este un parametru aleator scalar, continand informatia. In intervalul  $0 \leq t \leq T$  se fac  $N$  observatii  $r_1, \dots, r_N$ , constituite in vectorul  $\vec{r}$ . Se folosesc densitatile de probabilitate  $f_{\vec{r}|\Theta}(\vec{r} | \theta)$ ,  $f_{\Theta|\vec{R}}(\theta | \vec{r})$  si  $f_{\Theta}(\theta)$ ; se determina valoarea estimata  $\hat{\theta}(\vec{r})$  a lui  $\theta$ .

Eroarea estimarii este data de  $\epsilon_{\theta} = \theta - \hat{\theta}(\vec{r})$ . Pentru a evalua eroarea se defineste o functie de cost.

### 2.1 Functii de cost $C(\epsilon_{\theta})$

- patratul erorii


$$C(\epsilon_{\theta}) = \epsilon_{\theta}^2$$

- uniforma :

$$C(\epsilon_{\theta}) = \begin{cases} 0 & |\epsilon_{\theta}| \leq E/2 \\ 1 & |\epsilon_{\theta}| \geq E/2 \end{cases}$$

- modulul erorii :

$$C(\epsilon_{\theta}) = |\epsilon_{\theta}|$$



Valoarea medie a functiei de cost se numeste *risc*.

$$R = E\{C(\epsilon_{\theta})\} = \int_{-\infty}^{\infty} d\theta \int_{\Delta} C(\epsilon_{\theta}) \cdot f_{\Theta, \vec{R}}(\theta, \vec{r}) d\vec{r}$$

$\Delta \Rightarrow$  domeniul in care ia valori  $\vec{r}$

Valoarea estimata a parametrului se obtine minimizand riscul.

Se pune riscul sub o forma in care se poate face minimizarea acestuia functie de observatiile efectuate:

$$\begin{aligned}
R &= E\{C(\epsilon_\theta)\} = \int_{-\infty}^{\infty} d\theta \int_{\Delta} C(\epsilon_\theta) \cdot f_{\Theta, \bar{R}}(\theta, \vec{r}) dR = \\
&= \int_{-\infty}^{\infty} d\theta \int_{\Delta} C(\epsilon_\theta) \cdot f_{\Theta/\bar{R}}(\theta/\vec{r}) f_{\bar{R}}(\vec{r}) dR = \\
&= \int_{\Delta} f_{\bar{R}}(\vec{r}) dR \cdot \int_{-\infty}^{\infty} C(\epsilon_\theta) \cdot f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta
\end{aligned}$$

Minimizarea riscului se face minimizand in raport cu  $\hat{\theta}$  integrala definita:


$$I(\hat{\theta}, \vec{r}) = \int_{-\infty}^{\infty} C(\epsilon_\theta) \cdot f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta = \int_{-\infty}^{\infty} C(\theta - \hat{\theta}) \cdot f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta$$

$$\frac{\partial}{\partial \hat{\theta}} I(\hat{\theta}, \vec{r}) = 0$$

- pentru patratul erorii :  $I(\hat{\theta}, \vec{r}) = \int_{-\infty}^{\infty} (\theta - \hat{\theta})^2 \cdot f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta$

$$\frac{\partial}{\partial \hat{\theta}} I(\hat{\theta}, \vec{r}) = 2\hat{\theta} \int_{-\infty}^{\infty} f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta - 2 \int_{-\infty}^{\infty} \theta f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta = 0 \text{ sau}$$

$$\hat{\theta}_p = \int_{-\infty}^{\infty} \theta f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta \text{ deoarece } \int_{-\infty}^{\infty} f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta = 1$$



- pentru functia de cost uniforma:

$$I(\hat{\theta}, \vec{r}) = 1 - \int_{\hat{\theta}-E/2}^{\hat{\theta}+E/2} f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta = 1 - I_u(\theta, \vec{r}) \approx 1 - E f_{\Theta/\bar{R}}(\theta/\vec{r})$$

este minima pentru  $I_u(\theta, \vec{r})$  maxima. Se prefera sa se caute maximul

pentru  $\ln f_{\Theta/\bar{R}}(\theta/\vec{r})$  deoarece  $f_{\Theta/\bar{R}}(\theta/\vec{r})$  are in general o forma

exponentiala; ca urmare :

$$\frac{\partial}{\partial \theta} \ln f_{\Theta/\bar{R}}(\theta/\vec{r})|_{\theta=\hat{\theta}_{MAP}} =$$

$$\frac{\partial}{\partial \theta} \ln f_{\Theta}(\theta)|_{\theta=\hat{\theta}_{MAP}} + \frac{\partial}{\partial \theta} \ln f_{\bar{R}|\Theta}(\vec{r}|\theta)|_{\theta=\hat{\theta}_{MAP}} = 0$$

$$\text{daca se are in vedere } \frac{f_{\Theta/\bar{R}}(\theta/\vec{r}) \cdot f_{\bar{R}}(\vec{r})}{f_{\Theta}(\theta)} = f_{\bar{R}|\Theta}(\vec{r}|\theta)$$

unde  $\theta_{MAP}$  este estimatul maximum a posteriori.



- Pentru functia de cost modulul erorii:

$$I(\hat{\theta}, \vec{r}) = \int_{-\infty}^{+\infty} |\theta - \hat{\theta}_M| f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta \text{ si pentru minimizarea ei :}$$

$$\frac{\partial}{\partial \hat{\theta}} I(\hat{\theta}, \vec{r}) = 0, \text{ respectiv :}$$


$$\frac{\partial}{\partial \hat{\theta}} \int_{\hat{\theta}_M}^{+\infty} (\theta - \hat{\theta}_M) f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta - \frac{\partial}{\partial \hat{\theta}} \int_{-\infty}^{\hat{\theta}_M} (\theta - \hat{\theta}_M) f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta = 0$$

Rezulta pentru calculul estimatului  $\hat{\theta}_M$

$$\int_{\hat{\theta}_M}^{+\infty} f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta = \int_{-\infty}^{\hat{\theta}_M} f_{\Theta/\bar{R}}(\theta/\vec{r}) d\theta$$

$\hat{\theta}_M$  se numeste estimatul de eroare minima.

**Obs.:** O situatie a celor trei estimati, pentru densitati de probabilitate conditionate, de forma simetrica si nesimetrica, este data in figurile de mai jos.



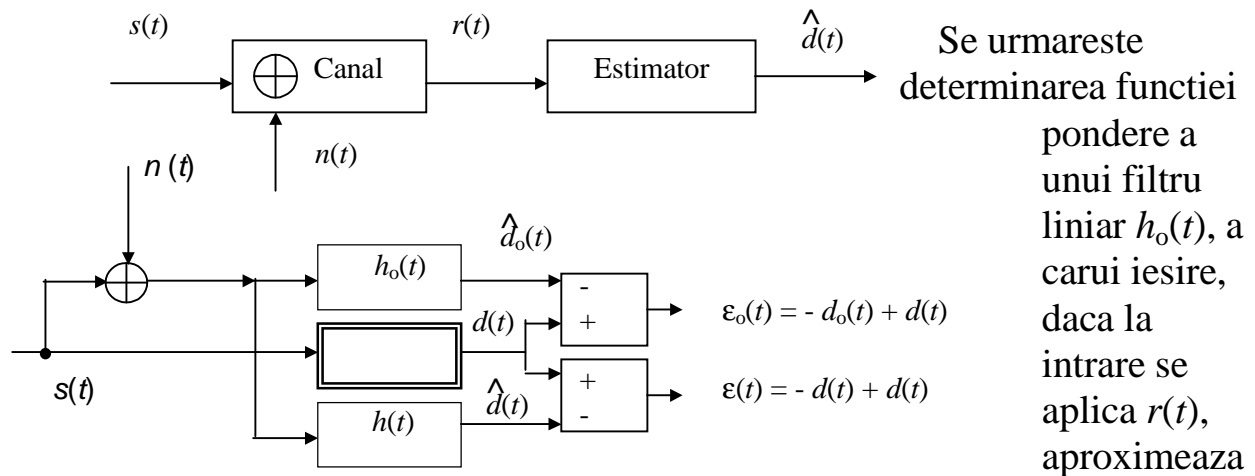
## Estimarea formei semnalului

Ipotezele de lucru:

- estimarea este liniara;
- semnalul receptionat si zgomotul sunt stationare in sens larg;
- criteriul de optim: minimul erorii medii patratice.

### 1. Filtrarea optima a semnalelor continue. Ecuatia Wiener – Hopf

Ce se urmareste: estimarea formei lui  $s(t)$  se face prin prelucrarea liniara a semnalului receptionat  $r(t) = s(t) + n(t)$ , astfel incat sa se obtina un semnal cat mai apropiat de semnalul dorit  $d(t)$  (filtrare optima in sens Wiener – Kolmogorov).



cu eroare medie patratice minima, semnalul dorit  $d(t)$ . In schema de mai sus  $h(t)$  corespunde unui filtru neoptimal, care furnizeaza un semnal care aproximeaza semnalul dorit cu eroare medie patratice mai mare ca cea

minima. Ar trebui:  $\overline{[\epsilon_o(t)]^2} = \min \overline{[\epsilon(t)]^2}$

$$\overline{[\epsilon(t)]^2} = \overline{(d(t) - \hat{d}(t))^2}$$

$$\hat{d}(t) = \int_{-\infty}^{\infty} h(\tau) r(t - \tau) d\tau = \mathcal{L}[r(t)]$$

$$\overline{[\epsilon_o(t)]^2} = \overline{(d(t) - \hat{d}_o(t))^2}$$

$$\hat{d}_o(t) = \int_{-\infty}^{\infty} h_o(\tau) r(t - \tau) d\tau = \mathcal{L}_o[r(t)]$$

$$\overline{[\epsilon_o(t)]^2} = \min \overline{[\epsilon(t)]^2}$$


$$\overline{[\varepsilon(t)]^2} = \overline{(d - \hat{d})^2} = \overline{[(d - \hat{d}_o) - (\hat{d} - \hat{d}_o)]^2} = \overline{[\varepsilon_o(t)]^2} + \delta^2 - 2\overline{[(d - \hat{d}_o)(\hat{d} - \hat{d}_o)]} \quad \text{unde } \delta = \hat{d} - \hat{d}_o. \text{ Ultimul termen devine:}$$

$$2\overline{[(d - \hat{d}_o)(\hat{d} - \hat{d}_o)]} = 2\overline{[d - \mathcal{L}_o\{r(t)\}][\mathcal{L}\{r(t)\} - \mathcal{L}_o\{r(t)\}]} = 2\overline{\varepsilon_o(t)\mathcal{L}'\{r(t)\}} = 2\overline{\mathcal{L}'\{r(t)\}\varepsilon_o(t)} = 2\overline{\mathcal{L}'\{r(t) \cdot \varepsilon_o(t)\}}$$

Pentru filtru optimal  $\varepsilon_o(t)$  si  $r(t)$  sunt ortogonale deci au loc relatiile:

$$\overline{\varepsilon_o(t) \cdot r(u)} = 0 \quad \text{si} \quad c_{\varepsilon_o r}(t, u) = 0 \quad \forall t, u \quad \text{deci:}$$

$$\overline{r \cdot \varepsilon_o(t)} = \overline{[d(t) - \hat{d}_o(t)]r} = 0 \quad \text{de unde:}$$



$$\overline{d(t)r(u)} = \overline{\hat{d}_o(t)r(u)} \quad \forall t, u \quad \text{si deoarece } \hat{d}_o = \int_{-\infty}^{\infty} h_{on}(\tau)r(t-\tau)d\tau$$

$$c_{dr}(t-u) = \int_{-\infty}^{\infty} h_{on}(\tau)\overline{r(t-\tau)r(u)}d\tau \quad \text{sau:}$$

$$c_{dr}(t-u) = \int_{-\infty}^{\infty} h_{on}(\tau)c_{rr}(t-\tau-u)d\tau \quad \text{sau, introducand variabila } \theta = t-u:$$

$$c_{dr}(\theta) = \int_{-\infty}^{\infty} h_{on}(\tau)c_{rr}(\theta-\tau)d\tau \quad \text{care este ecuatia Wiener - Hopf;}$$

aceasta permite determinarea lui  $h_{on}(t)$ . Aplicand transformata Fourier:

$$q_{dr}(\omega) = H_{on}(\omega)q_{rr}(\omega) \Rightarrow$$

$$H_{on}(\omega) = \frac{q_{dr}(\omega)}{q_{rr}(\omega)} = \frac{q_{dr}(\omega)}{q_{ss}(\omega) + q_{nn}(\omega)} = \frac{q_{ss}(\omega)}{q_{ss}(\omega) + q_{nn}(\omega)}$$

pentru semnale  $s(t)$  si  $n(t)$  independente.

Se obtine astfel functia de transfer a unui filtru nerealizabil (nu s-a impus ca  $h(t) = 0$  pentru  $t < 0$ ) care se poate aproxima insa cu filtre realizabile.

*Exemplu:* Fie  $d(t) = s(t + \alpha)$  unde  $s(t)$  este mesajul transmis. Daca:

- $\alpha = 0$ , avem o filtrare simpla (estimarea se face pt. toate valorile trecute ale timpului)
- $\alpha < 0$ , avem o filtrare cu intarziere (netezire): estimarea se face cu intarziere dar se utilizeaza mai multe date, deci eroarea este mai mica.
- $\alpha > 0$ , avem o filtrare cu predictie (anticipare): estimarea se face in avans dar se utilizeaza mai putine date, deci eroarea este mai mare.

In domeniul frecvență, vom avea respectiv, următoarele funcții de transfer ale unor filtre optime nerealizabile:

$$H_{on}(\omega) = \frac{q_{ss}(\omega)}{q_{ss}(\omega) + q_{nn}(\omega)}$$

$$H_{on}(\omega) = \frac{q_{ss}(\omega)}{q_{ss}(\omega) + q_{nn}(\omega)} \exp(-j\omega\alpha)$$

$$H_{on}(\omega) = \frac{q_{ss}(\omega)}{q_{ss}(\omega) + q_{nn}(\omega)} \exp(+j\omega\alpha)$$



*Exemplu:* Filtu optim nerealizabil, continuu în timp. Sunt valabile:

$$q_{ss}(\omega) = \frac{q_s}{1 + a^2 \omega^2}, \quad q_{nn}(\omega) = q_0$$

$$H_{on}(\omega) = \frac{q_{ss}(\omega)}{q_{ss}(\omega) + q_{nn}(\omega)} \exp(-j\omega\alpha) = \frac{2AB}{B^2 + \omega^2} \exp(-j\omega\alpha) \quad \text{cu}$$

$$A = \frac{1}{2a} \sqrt{\frac{q_s}{q_0} \frac{q_s}{q_s + q_0}}, \quad B = \frac{1}{a} \sqrt{1 + \frac{q_s}{q_0}}$$

$$h_{on}(\tau) = A \exp(-B|\tau - \alpha|)$$



## Filtru optimal realizabil

Daca se fac schimbarile de variabile  $t - u \rightarrow \tau$ ,  $\tau \rightarrow t$ , avem:


$$c_{dr}(\tau) = \int_{-\infty}^{\infty} h_{on}(t) c_{rr}(\tau - t) dt = {}^+ c_{dr}(\tau) + {}^- c_{dr}(\tau)$$

$${}^+ c_{dr}(\tau) = \int_0^{\infty} h_{on}(t) c_{rr}(\tau - t) dt =$$

$$= \begin{cases} c_{dr}(\tau), & \tau \geq 0 \\ 0 & \tau < 0 \end{cases}$$

$${}^- c_{dr}(\tau) = \int_{-\infty}^0 h_{on}(t) c_{rr}(\tau - t) dt =$$

$$= \begin{cases} c_{dr}(\tau), & \tau < 0 \\ 0 & \tau \geq 0 \end{cases}$$



Filtrul optimal realizabil (cauzal) poate fi obtinut numai din  ${}^+ c_{dr}(\tau)$ . Functia de transfer se obtine prin transformarea Fourier inversa a acestuia:

$$H_o(\omega) \cdot q_{rr}^+(\omega) = \int_{-\infty}^{\infty} {}^+ c_{dr}(\tau) \exp(-j\omega\tau) d\tau = {}^+ q_{dr}(\omega)$$

$$H_o(\omega) = \frac{{}^+ q_{dr}(\omega)}{q_{rr}(\omega)}$$

### 1.1. Filtre optime pentru zgomot alb (FOW)

$$r(t) = z(t)$$

$$c_{rr}(\tau) = c_{zz}(\tau) = \frac{N_0}{2} \delta(\tau); \text{ daca se considera } \frac{N_0}{2} = 1:$$


$$c_{dr}(\tau) = \int_0^{\infty} h_{ow}(t) c_{rr}(\tau - t) dt = \int_0^{\infty} h_{ow}(t) \delta(\tau - t) dt = h_{ow}(\tau) = c_{dz}(\tau)$$

Obs : la filtrul optimal pentru zgomot alb, functia pondere este covariatia dintre semnalul dorit si zgomot.

In domeniul frecventa, deoarece  $q_{zz} = 1$ :

$$H_{ow}(\omega) = {}^+ q_{dz}(\omega)$$

## 1.2. Filtre optimale Wiener pentru un semnal oarecare



$$q_{zz}(s) = W(s) \cdot W(-s) q_{rr}(s)$$

$$W(s) \cdot W(-s) = \frac{1}{q_{rr}^+(s) q_{rr}^-(s)}$$

daca se iau numai partile realizabile :

$$W(s) = \frac{1}{q_{rr}^+(s)}$$


$$H_{ow}(s) = W^{-1}(s) H_{or}(s)$$

$$H_o(s) = \frac{H_{ow}(s)}{W^{-1}(s)}$$

FA: filtrul de albire  
FIA: filtrul invers de albire  
FO: filtrul optimal pentru  $r(t)$   
FOW: filtrul optimal pentru zgomet alb

## 1.3. Filtrarea optima Wiener prin extragerea zgometului

Ce se urmareste: estimarea formei lui  $s(t)$  se face prin estimarea lui  $n(t)$  si extragerea acestuia din  $r(t)$ . Schema de extragere se da mai jos, unde:

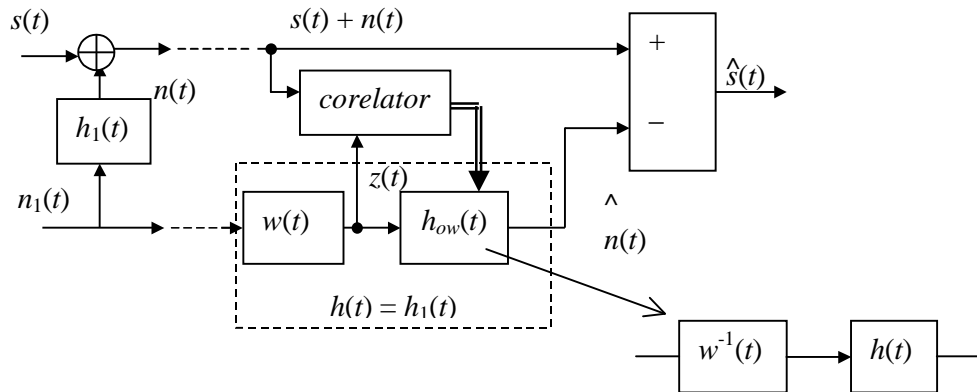


$n_1(t)$  = zgometul captat din semnal  
 $n(t)$  = zgometul filtrat  
 $h_1(t)$  = functia pondere a legaturii dintre cele doua componente captate

$s(t)$  si  $n_2(t)$  ale semnalului. Deoarece  $h_1(t)$  este necunoscut,  $h(t) = h_1(t)$  poate fi determinat numai indirect printr-un procedeu de optimizare.

$$H_1(s) = \frac{q_{nn_1}(s)}{q_{n_1 n_1}(s)} = \frac{q_{rn_1}(s)}{q_{n_1 n_1}(s)} \cong H(s)$$

O metoda de calcul rapid a lui  $H(s)$  este cea de mai jos in care se face apel la un corelator a lui  $r(t)$  cu zgomotul alb  $z(t)$ :



$$H_1(s) = \frac{q_{nn_1}(s)}{q_{n_1n_1}(s)} = \frac{q_{rn_1}(s)}{q_{n_1n_1}(s)} = \frac{q_{zn_1}(s)}{q_{n_1n_1}(s)} \frac{q_{rz}(s)}{q_{zz}(s)} \approx$$


$$\approx \frac{q_{zn_1}(s)}{q_{n_1n_1}(s)} \frac{q_{nz}(s)}{q_{zz}(s)} = W(s)H_{ow}(s) = H(s)$$

unde  $H_{ow}(s) = W^{-1}(s)H(s)$  este dat de corelator.

## 2. Filtrul optimal Kalman – Bucy

a) Cazul ideal:  $\hat{d}(t) = s(t)$

Este o varianta de filtru optimal Wiener in care se realizeaza FOW printr-un sistem dinamic iar intrarea filtrului de albire este diferenta dintre semnalul receptionat si estimatul semnalului dorit. Aici sistemele



dinamice sunt generatoare de semnale aleatoare, fiind excitate de zgomot alb. Problema este de a determina functia de transfer a sistemului de asa natura incat la iesire lui sa se obtina un semnal a carui densitate spectrala de putere este cea a semnalului dorit:

$$q_{zz}(s)H_o(s)H_o(-s) = q_{ss}(s)$$

Obs.: daca  $n(t) = z(t)$ ,  $K = \text{const.}$

*Exemplu:* Se doreste:

$$q_{ss}(s) = \frac{K_0}{\alpha^2 - s^2};$$

Deoarece  $q_{zz}(s) = \frac{1}{2} N_0 = K :$

$$H_o(s)H_o(-s) = \frac{K_0}{K} \frac{1}{\alpha^2 - s^2} = \frac{K_0}{K} \frac{1}{\alpha - s} \frac{1}{\alpha + s}$$

Pentru filtru realizabil se ia numai partea realizabila  $H_o(s) = \sqrt{\frac{K_0}{K}} \frac{1}{\alpha + s}$

Daca  $q_{ss}(s)$  dorit se descrie cu o aproximatie Butterworth de ordin mai mare va fi necesar un sistem dinamic de ordin superior, descris de :

- ecuatie diferentiala liniara cu coeficienti constanti :

$$y^{(n)}(t) + a_{n-1}y^{(n-1)}(t) + \dots + a_0y(t) = b_{n-1}u^{(n-1)}(t) + \dots + b_0u(t)$$

- functie de transfer corespunzatoare :


$$H(s) = \frac{Y(s)}{U(s)} = \frac{b_{n-1}s^{n-1} + \dots + b_0}{s^n + a_{n-1}s^{n-1} + \dots + a_0}$$

- ecuatii de stare si de iesire corespunzatoare :

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t)$$

$$\mathbf{y}(t) = \mathbf{C}\mathbf{x}(t)$$


$$\mathbf{A} = \begin{bmatrix} -a_{n-1} & 1 & 0 & \dots & 0 \\ -a_{n-2} & 0 & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots & \dots \\ -a_1 & 0 & 0 & \dots & 1 \\ -a_0 & 0 & 0 & \dots & 0 \end{bmatrix} \quad \mathbf{B} = \begin{bmatrix} b_{n-1} \\ b_{n-2} \\ \dots \\ b_0 \end{bmatrix} \quad \mathbf{C} = [10\dots0] \text{ (o singura iesire)}$$



Modelul sistemului dinamic generator de semnal aleator este dat alaturat (  $\mathbf{u}(t) = \mathbf{z}(t)$  si  $\mathbf{x}(t) = \mathbf{d}(t)$  )



*Exemplu:* fie schema din figura de mai jos, in care variabila de stare este tensiunea la bornele condensatorului,  $v_c(t)$ .



Se cere:

1. modelul matematic, respectiv ecuatia de stare a circuitului
2. structura sistemului dinamic generator al semnalului  $s(t) = v_c(t)$
3.  $s(t)$  pentru  $v(t) = 0$  si  $v_c(0) = V = v.a.$
4. structura sistemului dinamic generator al semnalului  $s(t) = v_c(t)$  in cazul (3).
5. sa se arate ca in cazul (3)  $s(t)$  este un proces aleator nestationar
6. functia de transfer a sistemului dinamic generator pentru  $v_c(0) = V = 0$  si  $v(t) = z(t)$ , adica zgomot alb
7. sa se arate ca  $s(t)$  obtinut in conditiile de la (6) este un proces aleator stationar; care este relatia dintre D.S.P. a lui  $v(t) = z(t)$  si varianta  $\sigma_y^2$

Solutie:

$$1. \quad v_R(t) + v_C(t) = v(t)$$

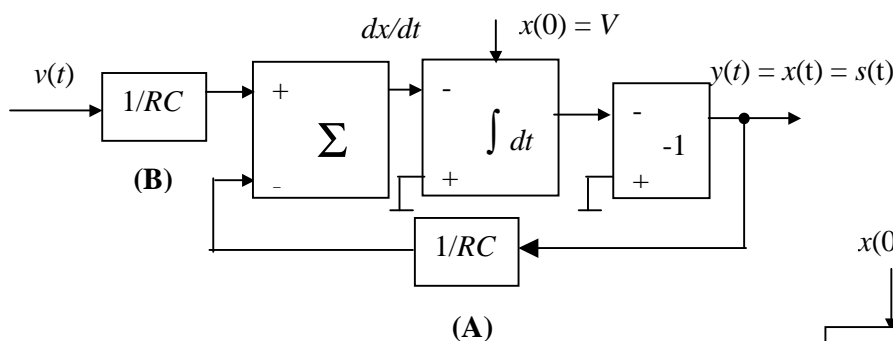
$$x(t) = v_C(t) = s(t)$$

$$\frac{dx(t)}{dt} = -\frac{1}{RC}x(t) + \frac{1}{RC}v(t)$$

$$y(t) = s(t)$$


$$\mathbf{A} = \left[ -\frac{1}{RC} \right]; \quad \mathbf{B} = \left[ \frac{1}{RC} \right]; \quad \mathbf{C} = [1]$$

$$2. \quad X(s) = \left[ -\frac{1}{RC}X(s) + x(0) \right] \frac{1}{s} + \frac{1}{RC} \frac{1}{s} V(s)$$



$$3. \quad s(t) = y(t) = x(t) = \\ = V \exp\left(-\frac{1}{RC}t\right)$$

4.



5. dacă  $v(t) = 0$  și  $v_c(0) = V =$  v.a. cu densitate de probabilitate  $f_V(V)$ , atunci la momentul  $t = t_1$ :  $f_y(y, t_1) = f_V(V) \exp\left(-\frac{1}{RC}t_1\right)$  deci rezulta ca  $y(t)$  este un proces aleator nestationar deoarece densitatea de probabilitate variaza cu timpul.

6.  $H(s) = \frac{k}{s + k}$  unde :  $k = 1/RC$

7.

$$q_{vv}(s) = N_0 / 2$$

$$q_{yy}(s) = H(s)H(-s)q_{vv}(s) = \frac{k^2 N_0 / 2}{k^2 - s^2} \quad q_{yy}(\omega) = \frac{k^2 N_0 / 2}{k^2 + \omega^2}$$

Obs.: deoarece  $q_{yy}(\omega)$  este o fracție ratională patratică,  $y(t)$  este proces aleator stationar.

Dacă se ia partea realizabilă a lui  $q_{yy}(s)$  care este :  ${}^+q_{yy}(s) = \frac{kN_0 / 4}{k + s}$

$$\sigma_y^2 = R(0) - R(\infty) = \lim_{s \rightarrow \infty} s \cdot {}^+q_{yy}(s) - \lim_{s \rightarrow 0} s \cdot {}^+q_{yy}(s) = kN_0 / 4 - 0 = kN_0 / 4$$

Deci pentru ca semnalul generat să aibă varianța  $\sigma_y^2$  trebuie ca zgomotul alb care excita sistemul dinamic generator să se caracterizeze prin :

$$N_0 / 2 = 2\sigma_y^2 / k$$

**b) Cazul general** ( $\hat{s}(t) \neq s(t)$ )

Sistemul dinamic (sursa) care genereaza semnalul aleator este:

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t)$$

$$\mathbf{y}(t) = \mathbf{C}\mathbf{x}(t) + \mathbf{n}(t) = \mathbf{s}(t) + \mathbf{n}(t) = \mathbf{r}(t)$$

$$\mathbf{x}(t_0) = \xi$$

Se noteaza:

$$\bar{\xi} = \mathbf{x}_0$$

$$E[\mathbf{u}(t)] = \bar{\mathbf{u}}(t)$$

$$E[\mathbf{n}(t)] = \bar{\mathbf{n}}(t)$$

Avem urmatoarele relatii pentru covariante ( $\mathbf{u}(t)$  si  $\mathbf{n}(t)$  sunt zgomote albe):

$$\overline{[\xi - \mathbf{x}_0][\xi - \mathbf{x}_0]^T} = \mathbf{c}_{\xi\xi 0}$$

$$\overline{[\mathbf{u}(t) - \bar{\mathbf{u}}(t)][\mathbf{u}(\tau) - \bar{\mathbf{u}}(\tau)]^T} = \mathbf{c}_{uu}(t - \tau) = \mathbf{Q}\delta(t - \tau) \quad \forall t, \tau \geq 0$$

$$\overline{[\mathbf{n}(t) - \bar{\mathbf{n}}(t)][\mathbf{n}(\tau) - \bar{\mathbf{n}}(\tau)]^T} = \mathbf{c}_{nn}(t - \tau) = \mathbf{P}\delta(t - \tau) \quad \forall t, \tau \geq 0$$

si urmatoarele necorelari:

$$\overline{[\xi - \mathbf{x}_0][\mathbf{u}(t) - \bar{\mathbf{u}}(t)]^T} \equiv 0 \quad \forall t \geq 0$$

$$\overline{[\xi - \mathbf{x}_0][\mathbf{n}(t) - \bar{\mathbf{n}}(t)]^T} \equiv 0 \quad \forall t \geq 0$$

$$\overline{[\mathbf{n}(t) - \bar{\mathbf{n}}(t)][\mathbf{u}(t) - \bar{\mathbf{u}}(t)]^T} = \mathbf{c}_{nu}(t) \equiv 0 \quad \forall t \geq 0$$

Se urmareste gasirea unui observator de stare optimal de forma:

$$\frac{d\hat{\mathbf{x}}(t)}{dt} = \mathbf{F}(t)\hat{\mathbf{x}}(t) + \mathbf{K}(t)\mathbf{y}(t) + \mathbf{m}(t)$$

$$\hat{\mathbf{x}}(t_0) = \mathbf{x}_0$$

cu cerintele de optimalitate:

1. estimare fara eroare sistematica :

$$\overline{\mathbf{x}(t) - \hat{\mathbf{x}}(t)} \equiv 0$$

2. covarianta matriciala a erorii de estimare este minimala :

$$\mathbf{c}_{\xi\xi opt}(t) \leq \mathbf{c}_{\xi\xi}(t) = \overline{[\mathbf{x}(t) - \hat{\mathbf{x}}(t)][\mathbf{x}(t) - \hat{\mathbf{x}}(t)]^T}$$

Se propune solutia:

$$\frac{d\hat{\mathbf{x}}(t)}{dt} = \mathbf{A}\hat{\mathbf{x}}(t) + \mathbf{B}\bar{\mathbf{u}}(t) + \mathbf{c}_{\varepsilon\varepsilon}(t)\mathbf{C}^T\mathbf{P}^{-1}[\mathbf{y}(t) - \bar{\mathbf{n}}(t) - \mathbf{C}\hat{\mathbf{x}}(t)]$$

$$\hat{\mathbf{x}}(t_0) = \mathbf{x}_0$$

sau, pentru  $E[\mathbf{n}(t)] = 0 = E[\mathbf{u}(t)]$  si sistem invariant in timp:

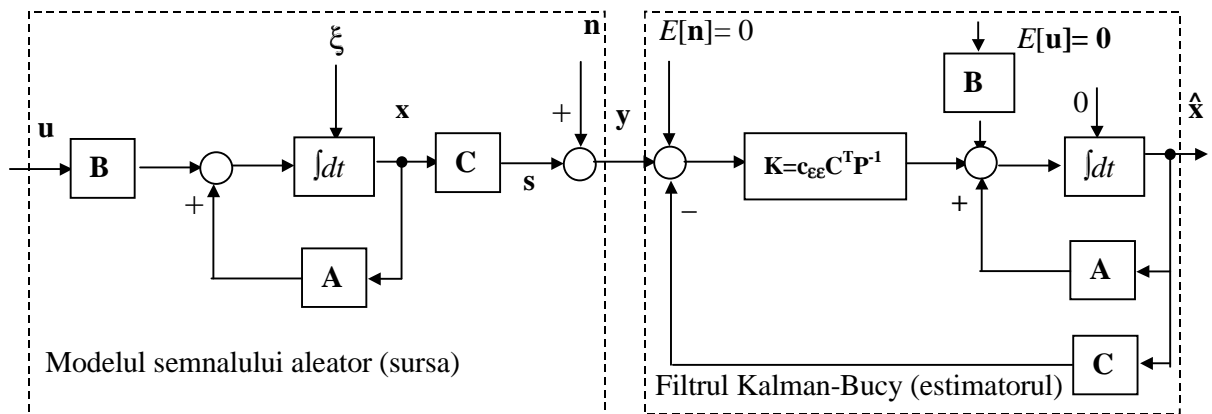
$$\frac{d\hat{\mathbf{x}}(t)}{dt} = \mathbf{A}\hat{\mathbf{x}}(t) + \mathbf{K}[\mathbf{y}(t) - \mathbf{C}\hat{\mathbf{x}}(t)]$$

$$\hat{\mathbf{x}}(t_0) = \mathbf{x}_0$$

unde  $\mathbf{K} = \mathbf{c}_{\varepsilon\varepsilon}\mathbf{C}^T\mathbf{P}^{-1}$  se numeste castigul filtrului in regim permanent iar  $\mathbf{c}_{\varepsilon\varepsilon}$  se determina din ecuatia Riccati<sup>1</sup> pentru regimul permanent:

$$\mathbf{A}\mathbf{c}_{\varepsilon\varepsilon} + \mathbf{c}_{\varepsilon\varepsilon}\mathbf{A}^T + \mathbf{B}\mathbf{Q}\mathbf{B}^T - \mathbf{c}_{\varepsilon\varepsilon}\mathbf{C}^T\mathbf{P}^{-1}\mathbf{C}\mathbf{c}_{\varepsilon\varepsilon} = \frac{d\mathbf{c}_{\varepsilon\varepsilon}}{dt} = 0$$

Schema fluxului de semnal la filtrul optimal Kalman-Bucy se da mai jos:



Pentru un sistem stochastic de ordinul 1:

$$\frac{dx(t)}{dt} = Ax(t) + Bu(t)$$

$$y(t) = x(t) + n(t)$$

$$u(t) : \{0; Q\}$$

$$n(t) : \{0; P\}$$

unde matricile  $A, B, P, Q$  au cate un singur element.

<sup>1</sup> Pentru justificarea ecuatiei Riccati vezi NOTA

$2Ac_{\varepsilon\varepsilon} - \frac{c_{\varepsilon\varepsilon}^2}{P} + B^2Q = 0$  este ecuatia Riccati, solutia pozitiva fiind :

$$c_{\varepsilon\varepsilon opt} = AP + \sqrt{A^2P^2 + B^2QP};$$

Filtrul Kalman este :

$$\frac{d\hat{x}(t)}{dt} = \sqrt{A^2 + \frac{B^2Q}{P}}\hat{x}(t) + \left( A + \sqrt{A^2 + \frac{B^2Q}{P}} \right) y(t)$$

*Exemplu:* prin canalul cu zgomot aditiv  $n(t)$ , avand  $c_{nn} = N_0 / 2$  (zgomot alb) se transmite un semnal  $s(t) = x(t)$ , avand:

$$q_{ss}(\omega) = \frac{2a}{a^2 + \omega^2} \text{ si sistemul dinamic generator al } s(t) = x(t), \text{ are functia}$$

$$\text{de transfer: } H(\omega) = \frac{1}{a + j\omega} \text{ sau } H(s) = \frac{1}{a + s} \text{ rezulta:}$$

$$q_{xx}(\omega) = q_{ss}(\omega) = q_{vv}(\omega) |H(\omega)|^2 \text{ de unde } q_{vv}(\omega) = 2a \text{ iar modelul de}$$

sistem dinamic este de forma:

$$\frac{dx(t)}{dt} = -ax(t) + u(t);$$

$$y(t) = x(t) + n(t)$$

$$\text{deci rezulta : } A = [-a]; \quad B = [1]; \quad C = [1];$$

la care se aduga:

$$Q = [2a]; \quad P = [N_0 / 2], \text{ vom avea ecuatia Riccati de forma:}$$

$$-2ac_{\varepsilon\varepsilon} - \frac{c_{\varepsilon\varepsilon}^2}{N_0 / 2} + 2a = 0, \text{ solutia pozitiva fiind :}$$

$$c_{\varepsilon\varepsilon} = -aN_0 / 2 + \sqrt{a^2(N_0 / 2)^2 + 2a};$$

Filtrul Kalman este de forma :

$$\frac{d\hat{x}(t)}{dt} = -\sqrt{a^2 + \frac{4a}{N_0}}\hat{x}(t) + \left( -a + \sqrt{a^2 + \frac{4a}{N_0}} \right) y(t)$$

Castigul filtrului in regim permanent are expresia:

$$K = -a + \sqrt{a^2 + \frac{4a}{N_0}} = \frac{c_{\varepsilon\varepsilon}}{N_0 / 2}$$

Obs.: In regim tranzitoriu,  $c_{\varepsilon\varepsilon} \Rightarrow c_{\varepsilon\varepsilon}(t)$  si ecuatia Riccati devine:

$$-2ac_{\varepsilon\varepsilon}(t) - \frac{c_{\varepsilon\varepsilon}^2(t)}{N_0/2} + 2a = \frac{dc_{\varepsilon\varepsilon}(t)}{dt}$$
 , ecuatie care se poate modela computational, iesirea modelului actualizand permanent castigul filtrului.

